
Preparação e Integração de Dados

Pós-graduação em GESTÃO E ANÁLISE ESTRATÉGICA DE DADOS

Síntese da disciplina

Prof. Sheila Mara Oliveira Dias

1. CONCEITOS INICIAIS: COLETA, PREPARAÇÃO DE DADOS, PROCESSO DE DESCOBERTA DE CONHECIMENTO.

- Os DADOS são os registros soltos, aleatórios, sem quaisquer análise (Rezende, 2015).
- A INFORMAÇÃO seria qualquer estruturação ou organização desses dados.
- O CONHECIMENTO envolve entendimento, por alguém, de um padrão a ser seguido baseado em informação.



Business Intelligence (BI)

Business Intelligence (BI) é um termo abrangente que inclui aplicativos, infraestrutura, ferramentas e práticas que permitem: o acesso e a análise das informações para melhorar e otimizar decisões e desempenho das CORPORAÇÕES.

Os sistemas de Business Intelligence (BI) podem ser compreendidos como meios de transformação de dados [...]. Os dados coletados são extraídos, transformados e carregados em estruturas informacionais, oferecendo assim, desempenho e facilidade ao manipular os dados.

O Cenário do Self Service BI

- Ajuda a democratizar o emprego de *analytics* dentro das organizações;
- Amplia a capacitação de usuários negócios de todos os níveis (operacional/tático/estratégico).
- Criação da cultura de *governança de dados*.

GOVERNANÇA DE DADOS



1.Requisitos externos, conformidade e Patrocínio

- ✓ Regras de conformidade (*compliance*), LGPD
- ✓ Patrocínio/Incentivo de líderes

2.Objetivos e Resultados Chave

- ✓ **Criar** instrumentos (políticas, diretrizes), com os objetivos e resultados chave bem definidos.
- ✓ Gerar envolvimento e motivação na empresa .

3.Escritório de Governança de Dados

- ✓ Local na empresa cujo tema central: **dados**.
- ✓ Guardiões da Governança de Dados, sua missão, objetivos e resultados chave
- ✓ Visão sobre todas as dimensões: pessoas, processos e tecnologias

4. Dados críticos de negócio

- ✓ Foque nos dados mais valiosos relacionados aos processos chave ou associados a riscos.
- ✓ Custo x benefício

5. Catálogo/Linhagem de Dados

- ✓ Uma lista que identifica os dados a serem consumidos por cientistas de dados ou analistas de negócio.

- ✓ Descreve cada etapa pela qual o dado passou desde a sua coleta, processamento, armazenamento até o compartilhamento.

6. Normas, Padrões e Procedimentos

- ✓ São ferramentas excelentes para compartilhar conhecimento, aperfeiçoar a qualidade, aumentar a produtividade.

7. Camada acesso/compartilhamento de dados

- ✓ Entrega de dados aos clientes.
- ✓ É uma camada que precisa de forte apoio da TI.
- ✓ Surgimento das ferramentas para exploração e visualização de dados, consultas e compartilhamento aparecem aqui.

8. Qualidade dos dados

- ✓ Dados entregues serão utilizados principalmente para tomada de decisão, não é difícil entender que dado ruim será igual a decisão ruim.
- ✓ É possível medir a qualidade coletando a avaliação dos usuários sobre os repositórios, tabelas, *dataset*.

9. Segurança dos dados

- ✓ A identificação e o tratamento diferenciado de dados pessoais.
- ✓ Acesso restrito e controlado
- ✓ Uso protocolos seguros com criptografia.

IMPLEMENTAÇÃO




Figure Intro-1 The Planning and Design Thread.

Requisitos do negócio

- ✓ Envolve entrevistas e reuniões.
- ✓ Ocorre a identificação das fontes de dados.
- ✓ Acontecem descobertas significativas que afetarão as necessidades do negócio.


Arquitetura

- ✓ Definição/Compra de uma ferramenta.
- ✓ Definição do local (path) onde estão os dados.
- ✓ Dependência das tarefas.
- ✓ Agendamento das tarefas.

2. FONTES E TIPOS DE DADOS. APLICAÇÃO DE TÉCNICAS E ENTREGA DE DADOS.

IMPLEMENTAÇÃO

System
Implementation



“Construir um sistema de ETL é extraordinariamente difícil, porque está sujeito a realidades inevitáveis”.

Extração

- ✓ A primeira parte do processo ETL é coletar os dados das fontes de origem.
- ✓ Na grande maioria existem fontes heterogêneas de dados.
- ✓ Fontes comuns são bases de dados, flat-files, planilhas, páginas web, XML etc.

Transformação - Limpeza

- ✓ Correto
- ✓ Sem Ambiguidade
- ✓ Consistente
- ✓ Completo

Transformação

A fase de transformação consiste em aplicar uma série de regras ou funções sobre os dados extraídos.

Essas regras são baseadas nos requisitos de negócios levantados.

Carga

A carga dos dados pode ser quanto a frequência de 2 formas distintas:

- ✓ Incremental – acontece num tempo programado.
- ✓ Completa (fria) – acontece somente uma vez.

- Batch
 - Bancos relacionais e arquivos
 - Alta Latência
- Near RealTime
 - Soluções como CDC
 - Geralmente Banco relacionais
 - Delta de transformações
- Real Time
 - Baixa Latência
 - Transformações em memória
 - Fontes diversas

FERRAMENTAS

- ✓ Extração Rápida e entrega dos dados
- ✓ Capacidade de Escalar
- ✓ Possibilita lidar com maior volumes de dados
- ✓ Soluções Econômicas
- ✓ Interface Amigável

ESTRUTURA DOS DADOS

ESTRUTURADO

- ✓ Esquema pré-definido
- ✓ Possui tipos de dados bem definidos
- ✓ Distinção clara entre estrutura e dados
- ✓ Estrutura modifica-se com baixa frequência
- ✓ Ex: Tabelas BD


SEMIESTRUTURADO

- ✓ Nem sempre há um esquema
- ✓ Não possui tipos de dados bem definidos
- ✓ Distinção entre estrutura e dados não é clara
- ✓ Estrutura modifica-se com frequência
- ✓ Ex: XML, JSON

NÃO ESTRUTURADO

- ✓ Sem estrutura
- ✓ Maioria dos dados gerados no mundo
- ✓ Ex: vídeos, áudios, imagens, documentos, páginas web redes sociais etc.

3. PROJETO E DESENVOLVIMENTO ETL - ESTRUTURAÇÃO E CARGA.



Operação

- Para fazer a migração/publicação para a produção tão simples quanto possível, certifique-se de criar documentos de apoio à produção tais como:
 - Relatório final que identifica todos os artefatos produzidos ao longo do processo de desenvolvimento.
 - Documento de detalhes sobre os schedules da carga.

A missão da equipe de ETL

- A missão da equipe de ETL, no nível mais alto, é o de construir os bastidores de uma solução de *analytics*:
 - Fornecer dados de forma mais eficaz para o negócio.
 - Agregar valor aos dados nos passos de limpeza e transformação.
 - Proteger e documentar o fluxo dos dados

A missão da equipe de ETL

Para que isso ocorra são necessários 4 fases:

1. **Extração** de dados das fontes originais.
2. Garantir a qualidade e **limpeza** de dados.
3. **Transformar** os dados para atender os requisitos de negócio, mantendo coerência com as fontes originais.
4. **Carregar** os dados no repositório da ferramenta, proporcionando consulta, relatórios, e painéis.

Responsabilidade da equipe de ETL

- Definir escopo do processo ETL.
- Analisar performance das origens.
- Definir uma estratégia de qualidade dos dados.
- Documentar as regras de negócio.
- Desenvolver os códigos físicos dos processos de carga.
- Acompanhar processos quando migrados para produção/publicados.
- Realizar manutenção dos processos de carga.

REFERÊNCIAS BIBLIOGRÁFICAS

BARBIERI, C. Governança de Dados: práticas, conceitos e novos caminhos. Rio de Janeiro: Alta Books, 2020

BATINI, Carlo, SCANNAPIECO, Monica. Data Quality: Concepts, Methodologies and Techniques . Springer, 2010.

INMON, W. H. Building the Data Warehouse (4th Edition). Hungry Minds Inc,U.S, 2005.

KIMBALL, R., CASERTA, J. The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning and Delivering Data. Wiley; 1 edition, 2004.

PATIL, D. J.; MASON, H. Data Driven: Creating a Data Culture. 1ª Edição. O'Reilly Media, Inc., 2015. p.22.

MEMBERS, Association. Dama-Dmbok (): Data Management Body of Knowledge; Technics Publications;2Nd Edition, 2017