

PREPARAÇÃO E INTEGRAÇÃO DE DADOS

Sheila Dias

Projeto e Desenvolvimento ETL



PUC Minas Virtual

IMPLEMENTAÇÃO




Figure Intro-1 The Planning and Design Thread.

•Figure 1 The Kimball Lifecycle diagram.

•Kimball Group – <http://www.ralphkimball.com/>

IMPLEMENTAÇÃO

System
Implementation





Figure Intro-2 The Data Flow Thread.

ETL Process






*“Construir um sistema de ETL é extraordinariamente difícil,
porque está sujeito a realidades inevitáveis”.*

Ralph Kimball, 2005



Tudo nasce na Extração.....

- O primeiro passo para o SUCESSO de um projeto é a fase de extração




Fonte: (<https://pt.slideshare.net/VithordaSilvaeSilva/self-service-bi-com-power-bi/10>)

Extração

- A primeira parte do processo ETL é coletar os dados das fontes de origem.
- Na grande maioria existem fontes heterogêneas de dados.
- Fontes comuns são bases de dados, flat-files, planilhas, páginas *web*, *XML* etc.

Extração

- Uma vez que seu sistema ETL é iniciado logo se percebe a necessidade de *integração de fontes diferentes* é um grande desafio.



<https://www.confluent.io/blog/building-real-time-streaming-etl-pipeline-20-minutes/>

Acessado 09/08/2020



PUC Minas Virtual

IMPLEMENTAÇÃO

System
Implementation




Figure Intro-2 The Data Flow Thread.

Transformação - Limpeza

■ Definindo Dados com Qualidade


- ✓ Correto
- ✓ Sem Ambiguidade
- ✓ Consistente
- ✓ Completo



Transformação - Limpeza

■ Analisando Dados com Anomalias

- ✓ O que é?
- ✓ Consequências ?
- ✓ Técnicas de Detecção?



Transformação - Limpeza

- **Dados com Anomalias - O que é?**

Um dado anômalo é aquele que não se encaixa no domínio do resto dos dados que são armazenados.



Transformação - Limpeza

- **Dados com Anomalias - Consequências?**
 - ✓ **Retrabalhos** são gerados em processos ETL quando expostos a anomalias não identificadas previamente.
 - ✓ Detecção de dados anômalos consome grande quantidade de tempo e análise. Ao fazer esta análise antes, irá economizar tempo e reduzir a frustração.

Transformação - Limpeza

■ Dados com Anomalias - Técnicas de Detecção?

- ✓ Para cada uma das fontes de dados a serem carregadas, deve-se fazer uma verificação do perfil dos dados, por amostragem, sendo mais comum:
 - Histórico de contagens de registros por dia para as tabelas de origem.
 - Histórico dos totais de métricas de negócios por dia.
 - Identificar informações necessárias.

Transformação

- A fase de transformação consiste em aplicar uma série de regras ou funções sobre os dados extraídos.
- Essas regras são baseadas *nos requisitos de negócios levantados*.

Transformação

- Selecionar somente informações necessárias para serem carregadas;
- Desprezar campos nulos;
- Traduzir valores codificados (M para Masculino e F para Feminino);

Transformação

- Criar um novo valor calculado ($\text{Valor Venda} = \text{quantidade} * \text{preço unitário}$);
- Sumarizar múltiplas linhas de dados
- Hierarquizar dados;

Transformação

- Transformar colunas em linhas.
- Unir a mesma informação, mas vinda de fontes diferentes;
- Realizar junções cruzando dados de múltiplas origens (Integração dos dados);



PUC Minas Virtual

IMPLEMENTAÇÃO

System
Implementation





Figure Intro-2 The Data Flow Thread.

Carga

- A carga dos dados pode ser quanto a frequência de 2 formas distintas:
 - ✓ **Incremental** – acontece num tempo programado.
 - ✓ **Completa (fria)** – acontece somente uma vez.

Carga


A carga dos dados quanto a **arquitetura** pode ser feita:



Carga– Visão *Data Warehouse*

- A fase de ETL desde a extração do dado até sua carga em um modelo dimensional consome, pelo menos, 70% do tempo, esforço e despesa da maioria dos projetos de *Data Warehouse*.

(Kimball,2005)




<https://www.shutterstock.com>

Carga– Visão Data Warehouse


- Um *data warehouse* é um sistema que extrai, limpa, transforma, e carrega os dados de fontes **operacionais** (ETL) em uma estrutura de armazenamento de dados dimensional e, em seguida, apoia e implementa consulta e análise para fins de tomada de decisão.

(Kimball,2005)



ETL – Visão *Self Service BI*


- Os dados podem ser armazenados nos repositório interno das ferramentas SSBI, que tem por característica ter alto poder de compressão, índices otimizados.



Fonte: <https://blog.luz.vc/excel/como-habilitar-instalar-power-query-excel/>


ETL - Visões

The ETL Pipeline




Fonte: <https://www.timmitchell.net/post/2017/01/06/what-is-etl/>

Visão Self Service



Fonte: <https://blog.luz.vc/excel/como-habilitar-instalar-power-query-excel/>

Visão DW



<https://www.shutterstock.com>



PUC Minas Virtual



<https://www.shutterstock.com>

FERRAMENTAS ETL – SELF SERVICE BI

Benefícios

- ✓ Extração Rápida e entrega dos dados
- ✓ Capacidade de Escalar
- ✓ Possibilita lidar com maior volumes de dados
- ✓ Soluções Econômicas
- ✓ Interface Amigável



Ferramentas

- ✓ Microsoft - Power BI
- ✓ Tableau
- ✓ Qlik
- ✓ ThoughtSpot

Figure 1. Magic Quadrant for Analytics and Business Intelligence Platforms



Source: Gartner (February 2020)



PUC Minas Virtual

Sugestão

- ✓ Construir uma lista simples de 3 ou 4 ferramentas que atendam a maioria dos requisitos.
- ✓ Avaliar utilizando informações publicitárias.
- ✓ Entrar em contato com um vendedor para obter as informações necessárias.
- ✓ Obter referências de consumidores.





[Esta Foto](#) de Autor desconhecido está licenciada sob [CC BY-SA](#).

Não existe uma única resposta certa na escolha da ferramenta.

Por isso, ao escolher uma ferramenta, além de conhecer suas potencialidades, é necessário entender antecipadamente seus pontos fracos e estar preparado para atenuar suas consequências.



PUC Minas Virtual



	NOME	EMAIL	END
1	Fulano Maciel	fmaciел@pucminas.br	Rua Augusto,11, BH,MG

```
<?xml version="1.0" encoding="UTF-8" ?>
<cadastro>
  <nome>Fulano Maciel</nome>
  <e-mail>fmaciел@pucminas.br</e-mail>
  <endereço>Rua Augusto,11,BH,MG</endereço>
</cadastro>
```

Esse é o aluno Fulano Maciel
cujo e-mail para contato é o
fmaciел@pucminas.br.
O aluno atesta, em seu cadastro,
que reside em: Rua Augusto,11, BH,MG

ESTRUTURADO

SEMIESTRUTURADO

NÃO ESTRUTURADO

ESTRUTURADO



- Esquema pré-definido
- Possui tipos de dados bem definidos
- Distinção clara entre estrutura e dados
- Estrutura modifica-se com baixa frequência
- **Ex: Tabelas BD**

SEMIESTRUTURADO



- Nem sempre há um esquema
- Não possui tipos de dados bem definidos
- Distinção entre estrutura e dados não é clara
- Estrutura modifica-se com frequência
- **Ex: XML, JSON**

NÃO ESTRUTURADO



- Sem estrutura
- Maioria dos dados gerados no mundo
- **Ex: vídeos, áudios, imagens, documentos, páginas web, redes sociais etc.**



PUC Minas Virtual