

PREMISSAS DA REGRESSAO LINEAR SIMPLES

PREMISSAS DA REGRESSÃO LINEAR SIMPLES

❑ Análise de Outliers de resíduos

❑ Homocedasticidade

❑ Normalmente distribuído

$$e_i = y_i - \hat{y}_i$$

Média = 0

Variância constante

Covariância = 0

ANÁLISE DE OUTLIERS





Gráfico de Resíduos padronizados vs Valores ajustados

NORMALIDADE DOS RESÍDUOS

Teste de Shapiro Wilk

H_0 = distribuição normal : $p > 0.05$

H_1 = distribuição não normal : $p \leq 0.05$



ANÁLISE DA HOMOCEDASTICIDADE DOS RESÍDUOS


Homocedasticidade: A variância dos erros e , condicionada aos valores das variáveis explanatórias, **será constante**.

Teste Breusch-Pagan (Homocedasticidade)

H_0 = existe homocedasticidade : $p > 0.05$

H_a = não existe homocedasticidade : $p \leq 0.05$


Homocedasticidade



A dispersão dos resíduos é a mesma ao longo de X

$$\sigma^2 = \text{constante}$$


Heterocedasticidade



A dispersão dos resíduos é uma função linear de X

$$\sigma_i^2 = \sigma^2 X_i$$


Heterocedasticidade



A dispersão dos resíduos é uma função quadrática de X

$$\sigma_i^2 = \alpha_1 X_i + \alpha_2 X_i^2$$

Heterocedasticidade



A dispersão dos resíduos cresce de maneira quadrática com os valores de X

$$\sigma_i^2 = \sigma^2 X_i^2$$

TESTE - T

Avaliando a significância de cada parâmetro β do modelo

$$H_0 : \beta = 0$$

$$H_1 : \beta \neq 0$$

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + e_i$$

$$H_0: p - \text{valor} \geq 0,05$$

$$H_1: p - \text{valor} < 0,05$$

TESTE – T – FORMULAÇÃO DAS HIPÓTESES

- Para cada coeficiente de regressão β , a hipótese nula (H_0) geralmente afirma que não há efeito significativo.
- A hipótese alternativa (H_1), por outro lado, afirma que há um efeito significativo.
- Os testes são bilaterais

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

TESTE – T – ESTATÍSTICA DE TESTE

A estatística do teste é calculada usando a estimativa do coeficiente ($\hat{\beta}_1$) e seu erro padrão ($SE(\hat{\beta}_1)$).

A estatística do teste segue uma distribuição t de Student.

$$t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}$$

TESTE – T – ESTATÍSTICA DE TESTE

O desvio padrão do estimador de um coeficiente de regressão ($SE(\hat{\beta}_1)$) pode ser calculado usando a seguinte fórmula:

$$SE(\hat{\beta}_1) = \frac{s}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

onde:

- s é o desvio padrão dos resíduos do modelo (erro padrão residual),
- n é o número de observações,
- x_i são os valores da variável independente,
- $\bar{x}$ é a média dos valores da variável independente.

TESTE – T – ESTATÍSTICA DE TESTE

$$s = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - 2}}$$

onde:

y_i são os valores observados da variável dependente,

$\hat{y}_i$ são os valores previstos pela regressão.

TESTE - F

Avalia a significância global de um modelo de regressão linear, ou seja, para testar se pelo menos uma das variáveis independentes tem um efeito significativo sobre a variável dependente.

O teste F é comumente usado em modelos de regressão múltipla.

$$H_0: \beta_1 = \beta_2 = \beta_3 = \dots = \beta_k = 0$$

H_1 : Pelo menos um β_j é diferente de zero

$$H_0 = F_{calc} \leq F_{crítico} \text{ ou } p - \text{valor} \geq 0,05$$

$$H_1 = F_{calc} > F_{crítico} \text{ ou } p - \text{valor} < 0,05$$

TESTE – F – ESTATÍSTICA DE TESTE

A estatística do teste F é calculada como:

$$F = \frac{(SQR/q)}{(SQE/(n-k-1))}$$

Onde:

- **SQR** é a soma dos quadrados da regressão
- q é o número de coeficientes a serem testados (neste caso, q=k),
- **SQE** é a soma dos quadrados dos resíduos
- n é o número de observações,
- k é o número de variáveis independentes no modelo.

TESTE – F – ESTATÍSTICA DE TESTE

Soma dos Quadrados da Regressão (SQR):

$$SQR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

$\hat{y}_i$ são os valores previstos pela regressão para a observação

$\bar{y}$ é a média dos valores observados da variável dependente.

SQR, mais o modelo está explicando a variabilidade nos dados.

TESTE – F – ESTATÍSTICA DE TESTE

Soma dos Quadrados dos Erros (SQE):

$$SQE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

onde:

y_i são os valores observados da variável dependente,

$\hat{y}_i$ são os valores previstos pela regressão para a observação


COEFICIENTE DE DETERMINAÇÃO (R^2)

Como avaliar o modelo?

O **coeficiente de determinação (R^2)** estima a proporção da variabilidade da variável dependente (Y) que é explicada pelas(s) variáveis independentes do modelo de regressão.

$$R^2 = \frac{SQR}{SQT} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{\sum_{i=1}^n \hat{e}_i^2}{\sum_{i=1}^n y_i^2} = \hat{\beta}_1^2 \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n y_i^2}$$

Escala de R^2 :



```
Call:
lm(formula = custo ~ idade, data = dados)
```

Modelo a ser
criado

```
Residuals:
```

```
      Min       1Q   Median       3Q      Max
-463.37 -277.04  -45.04   218.15   751.27
```

Análise de
Resíduos

```
Coefficients:
```

Coefficientes estimados

Teste -t

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-558.949	368.759	-1.516	0.168
idade	61.868	8.582	7.209	9.16e-05 ***

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 389.7 on 8 degrees of freedom
```

```
Multiple R-squared:  0.8666,  $R^2$  Adjusted R-squared:  0.8499
```

```
F-statistic: 51.98 on 1 and 8 DF,  p-value: 9.161e-05
```

Teste F

OLS Regression Results

Dep. Variable:	y	R-squared:	0.942	R^2
Model:	OLS	Adj. R-squared:	0.939	
Method:	Least Squares	F-statistic:	291.1	
Date:	Wed, 23 Jan 2019	Prob (F-statistic):	1.47e-12	
Time:	16:51:04	Log-Likelihood:	-35.596	

→ Teste F

Coefficientes

	coef	std err	t	P> t	[0.025	0.975]
const	364.1800	13.765	26.457	0.000	335.261	393.099
x1	-1.0320	0.060	-17.062	0.000	-1.159	-0.905

→ Teste T

Omnibus:	0.433	Durbin-Watson:	2.235
Prob(Omnibus):	0.805	Jarque-Bera (JB):	0.115
Skew:	-0.182	Prob(JB):	0.944
Kurtosis:	2.926	Cond. No.	9.26e+03

→ Resíduos



PUC Minas
Virtual