

PREMISSAS DA REGRESSÃO LINEAR MÚLTIPLA

PREMISSAS DA REGRESSÃO LINEAR MÚLTIPLA

☐ Análise de Outliers de resíduos

☐ Homocedasticidade

☐ Normalmente distribuído

☐ Ausência de multicolinearidade e autocorrelação

$$e_i = y_i - \hat{y}_i$$

Média = 0

Variância constante

Covariância = 0

ANÁLISE DE OUTLIERS





Gráfico de Resíduos padronizados vs Valores ajustados

NORMALIDADE DOS RESÍDUOS

Teste de Shapiro Wilk

H_0 = distribuição normal : $p > 0.05$

H_1 = distribuição não normal : $p \leq 0.05$



ANÁLISE DA HOMOCEDASTICIDADE DOS RESÍDUOS


Homocedasticidade: A variância dos erros e , condicionada aos valores das variáveis explanatórias, será constante.

Teste Breusch-Pagan (Homocedasticidade)

H_0 = existe homocedasticidade : $p > 0.05$

H_a = não existe homocedasticidade : $p \leq 0.05$


Homocedasticidade



A dispersão dos resíduos é a mesma ao longo de X

$$\sigma^2 = \text{constante}$$


Heterocedasticidade



A dispersão dos resíduos é uma função linear de X

$$\sigma_i^2 = \sigma^2 X_i$$


Heterocedasticidade



A dispersão dos resíduos é uma função quadrática de X

$$\sigma_i^2 = \alpha_1 X_i + \alpha_2 X_i^2$$

Heterocedasticidade



A dispersão dos resíduos cresce de maneira quadrática com os valores de X

$$\sigma_i^2 = \sigma^2 X_i^2$$

TESTE - T

Avaliando a significância de cada parâmetro β do modelo

$$H_0 : \beta = 0$$

$$H_1 : \beta \neq 0$$

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + e_i$$

$$H_0: p - \text{valor} \geq 0,05$$

$$H_1: p - \text{valor} < 0,05$$

TESTE - F

Avalia a significância global de um modelo de regressão linear, ou seja, para testar se pelo menos uma das variáveis independentes tem um efeito significativo sobre a variável dependente.

O teste F é comumente usado em modelos de regressão múltipla.

$$H_0: \beta_1 = \beta_2 = \beta_3 = \dots = \beta_k = 0$$

$$H_1: \text{Pelo menos um } \beta_j \text{ é diferente de zero}$$

$$H_0 = F_{\text{calc}} \leq F_{\text{crítico}} \text{ ou } p\text{-valor} \geq 0,05$$

$$H_1 = F_{\text{calc}} > F_{\text{crítico}} \text{ ou } p\text{-valor} < 0,05$$


COEFICIENTE DE DETERMINAÇÃO (R^2)

Como avaliar o modelo?

O **coeficiente de determinação (R^2)** estima a proporção da variabilidade da variável dependente (Y) que é explicada pelas(s) variáveis independentes do modelo de regressão.

$$R^2 = \frac{SQR}{SQT} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{\sum_{i=1}^n \hat{e}_i^2}{\sum_{i=1}^n y_i^2} = \hat{\beta}_1^2 \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n y_i^2}$$

Escala de R^2 :



COEFICIENTE DE DETERMINAÇÃO (R^2)

R^2 x R^2 ajustado

R^2 é a proporção da variabilidade total da variável dependente explicada pela regressão

R^2 ajustado leva em conta o **número de variáveis independentes** no modelo e penaliza o modelo por incluir variáveis irrelevantes.



MULTICOLINEARIDADE

- **Preditores correlacionados com outros preditores**, resulta quando você tem fatores que são, de certa forma, um pouco **redundantes**.
- Ou seja, quando **duas ou mais variáveis independentes em um modelo de regressão encontram-se altamente correlacionadas**
- Examinar a matriz de correlação das variáveis independentes.
 - 0,70 Altamente correlacionadas
 - 0,80 Alerta



MULTICOLINEARIDADE

- O valor do fator de inflação da variância (VIF), que mede **quanto a variância do coeficiente estimado para uma variável é inflada** devido à multicolinearidade com as outras variáveis independentes.
- VIFs maiores que 10 indicam alta multicolinearidade, enquanto valores entre 5 e 10 podem ser preocupantes.
- A maneira mais simples de lidar com a multicolinearidade é excluir a variável multicolinear

Scatter plot de uma matriz de correlação



Scatter plot de uma matriz de correlação



call:

```
lm(formula = fat ~ . - id_pizza, data = dados)
```

Residuals:

Min	1Q	Median	3Q	Max
-11.2688	-2.2798	0.0192	2.1821	6.7930

P - valor do teste t

Estimador dos coeficientes

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.22820	0.67148	10.77	< 2e-16 ***
sodium	21.11931	0.62813	33.62	< 2e-16 ***
carb	-0.04968	0.01290	-3.85	0.000144 ***

signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.156 on 297 degrees of freedom

Multiple R-squared: 0.8772, Adjusted R-squared: 0.8764

F-statistic: 1061 on 2 and 297 DF, p-value: < 2.2e-16 **R² Ajustado**

Detalhamento da saída do PYTHON

Dep. Variable:	Consumo de cerveja (litros)	R-squared:	0.723	R^2
Model:	OLS	Adj. R-squared:	0.719	R^2 - ajustado
Method:	Least Squares	F-statistic:	187.1	
Date:	Mon, 28 Jun 2021	Prob (F-statistic):	1.19e-97	Teste F

	coef	std err	t	P> t	[0.025	0.975]
const	6.4447	0.845	7.627	0.000	4.783	8.107
Temperatura Media (C)	0.0308	0.188	0.164	0.870	-0.339	0.401
Temperatura Minima (C)	-0.0190	0.110	-0.172	0.863	-0.236	0.198
Temperatura Maxima (C)	0.6560	0.095	6.895	0.000	0.469	0.843
Precipitacao (mm)	-0.0575	0.010	-5.726	0.000	-0.077	-0.038
Final de Semana	5.1832	0.271	19.126	0.000	4.650	5.716

Estimadores dos coeficientes

Teste T



PUC Minas
Virtual