

COMPARAÇÃO DE MODELOS

COMPARAÇÃO DE MODELOS


Nº grande
de
possíveis
modelos

Como
selecionar
o melhor
modelo

Utilizar
avaliadores
de
qualidade

Selecionar
o Modelo
mais
PARCIMO-
NIOSO

Modelo Parcimonioso é o modelo que **melhor explica o fenómeno que estamos estudando da forma mais simples possível**, menor número de parâmetros.



Usados para **medir o quão bem um modelo se ajusta aos dados observados**.
Ajudam a determinar a **qualidade** geral do ajuste do modelo, sua **capacidade de generalização** e o equilíbrio entre ajuste e complexidade.

COMPARAÇÃO DE MODELOS

Utilizamos os avaliadores de qualidade de modelos para comparar os modelos e entender qual modelo **explica** melhor o fenômeno de maneira mais **parcimoniosa**

Principais métricas para comparação de Modelos



CRITÉRIO DE INFORMAÇÃO DE AKAIKE - AIC

Métrica usada para **comparar diferentes modelos estatísticos, especialmente em contextos de seleção de modelos**. Foi proposto por Akaike em 1973 e é uma **ferramenta valiosa para equilibrar a qualidade do ajuste do modelo e sua complexidade**.

Logaritmo natural da Soma dos quadrados dos resíduos

$$AIC = -n \cdot \ln \left(\overbrace{SQR/n} \right) + \underbrace{2p}_{\text{Nº de parâmetros}}$$

INTERPRETAÇÃO DO AIC

-  AIC, melhor o ajuste do modelo aos dados.
- O termo $-2 \cdot \ln(SQR)$ penaliza a qualidade do ajuste, **favorecendo modelos que explicam melhor a variabilidade dos dados.**
- O termo $2 \cdot p$ **penaliza a complexidade do modelo**, favorecendo modelos mais simples com menos parâmetros.

O objetivo é selecionar o modelo com o menor AIC, pois ele equilibra eficazmente a precisão do ajuste e a parcimônia do modelo. No entanto, o AIC não fornece uma medida absoluta de ajuste, apenas comparações relativas entre modelos.

CRITÉRIO DE INFORMAÇÃO BAYESIANO - BIC

Também conhecido como Critério de Schwarz, é uma métrica semelhante ao AIC, mas incorpora uma **penalização mais forte para modelos mais complexos**. Ele foi proposto por Gideon E. Schwarz em 1978 e é particularmente útil quando se deseja **evitar o sobreajuste**.

Logaritmo natural da Soma dos quadrados dos resíduos

$$BIC = -n \cdot \ln\left(\frac{SQR}{n}\right) + \underbrace{\ln(n)p}$$

P -> N° de parâmetros

N -> tamanho da amostra

INTERPRETAÇÃO DO BIC

-  BIC, melhor o ajuste do modelo aos dados.
- O termo $-2 * \ln(\text{SQR})$ penaliza a qualidade do ajuste.
- O termo $p * \ln(n)$ penaliza a complexidade do modelo, sendo a penalização mais forte do que no AIC.

O BIC tende a favorecer modelos mais simples do que o AIC, especialmente quando o tamanho da amostra é pequeno. Portanto, o BIC é uma escolha apropriada quando se deseja evitar a inclusão de variáveis desnecessárias e manter um modelo mais parcimonioso.

COMPARANDO O AIC E O BIC

- ❑ Ambos, o AIC e o BIC, são ferramentas valiosas para seleção de modelos e ajudam a encontrar um equilíbrio entre ajuste e complexidade.
- ❑ A escolha entre eles dependerá do objetivo específico da análise e das preferências do pesquisador:
 - O AIC pode ser preferível quando se busca um ajuste mais preciso.
 - O BIC é mais útil quando a simplicidade do modelo é priorizada para evitar o sobreajuste.
 - Ambos os critérios proporcionam insights importantes na tomada de decisões sobre seleção de modelos.

MAE – ERRO MÉDIO ABSOLUTO

Métrica de avaliação de modelos de regressão que **mede a média das diferenças absolutas** entre as previsões do modelo e os valores reais (observados).

$$MAE = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_i|$$

Onde:

- n -> número de observações.
- y_i -> valor real da variável dependente.
- $\hat{y}_i$ -> valor previsto pelo modelo.

INTERPRETAÇÃO DO MAE

Ele representa a **média das diferenças absolutas entre as previsões e os valores reais**, sem levar em conta a direção (positiva ou negativa) das diferenças.

Quanto  o valor do MAE, melhor o ajuste do modelo.

MSE – ERRO MÉDIO QUADRÁTICO

Métrica de avaliação de modelos de regressão que **mede a média dos quadrados das diferenças** entre as previsões do modelo e os valores reais.

$$MSE = \frac{1}{n} \sum_{j=1}^n (y_j - \hat{y}_i)^2$$

Onde:

- n -> número de observações.
- y_i -> valor real da variável dependente.
- $\hat{y}_i$ -> valor previsto pelo modelo.

INTERPRETAÇÃO DO MSE

O MSE penaliza erros maiores mais fortemente do que erros menores, devido à natureza dos quadrados. Assim como o MAE, quanto menor o valor do MSE, melhor o ajuste do modelo.



PUC Minas
Virtual