

TRANSFORMAÇÃO DE VARIÁVEIS

INTRODUÇÃO

Financeiros

Econômicos

Comportamento do consumo no varejo

Industria

Saúde

Redes Sociais

Segurança publica

INTRODUÇÃO

Já vimos que:

- A modelagem preditiva é essencial para análise de dados em diversas áreas.
- Abordagem teórica e estatística sólida é crucial para modelos precisos.

Responder perguntas a partir do fenômeno a ser estudado com as variáveis que eventualmente relacionam com esse fenômeno



Variáveis?
Podemos escolher os tipos que convém aos modelos?

INTRODUÇÃO


Notas de Alunos do
ENEM

- Faixa de Renda
- Escolaridade dos Pais
- Quantidade de horas de estudo no ano anterior ao vestibular

Análise de crédito

- Faixa de Renda
- Gastos mensais
- Perfil do cliente:
 - Gênero
 - Idade ...

INTRODUÇÃO



Modelo Preditivo Básico

- Estrutura do modelo:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \dots + e_i$$

- Variáveis preditoras (X) influenciam a variável resposta (Y).


Como podemos inserir importantes
variáveis qualitativas em modelos
preditivos

INCORPORANDO VARIÁVEIS QUALITATIVAS

- ✓ Na modelagem é comum encontrarmos diversos tipos de **modelos** que têm como **pré-requisito que todas as variáveis sejam numéricas**
- ✓ Desafios ao **lidar com variáveis qualitativas** importantes para o modelo.
- ✓ Uso de **variáveis *dummy*** como solução para inserção de variáveis qualitativas.

O QUE SÃO VARIÁVEIS DUMMY ?

Variáveis Dummy são **variáveis dicotômicas** ou binárias (0 ou 1) criadas para representar uma variável com duas ou mais categorias.




VARIÁVEIS DUMMY PARA DUAS CATEGORIAS

SEXO		SEXO_Feminino
Feminino	→	1
Masculino	→	0
Feminino	→	1
Feminino	→	1
Masculino	→	0
Feminino	→	1

Precisa da variável : SEXO_Masculino ?

VARIÁVEIS DUMMY PARA DUAS CATEGORIAS




Como ficaria o Modelo de regressão ?

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{DUMMY} + e_i$$

Onde:

- $\hat{\beta}_0$ representa o valor médio da variável resposta, para as observações que apresentam um valor 0 da variável x.
- A soma $\hat{\beta}_0 + \hat{\beta}_1$, representa o valor médio de y para as observações quando $x = 1$

UF
MG
SP
RJ
ES
MG
ES
SP
RJ
RJ
ES
MG
ES



UF_MG
1
2
3
4
1
0
2
3
3
4
1
0

EXEMPLO DE VARIÁVEIS DUMMY PARA MAIS DE DUAS CATEGORIAS

ERRADO!!!!

VARIÁVEIS DUMMY PARA MAIS DE DUAS CATEGORIAS

Por que está errado?

Dois valores próximos serão mais parecidos que valores distantes;

- MG(1) está mais próximo de SP(2) do que ES(4)


Por conta da diferença dos valores alguns atributos podem ter **maior peso** que os outros;

- ES -> Peso 4
- MG -> Peso 1

VARIÁVEIS DUMMY PARA MAIS DE DUAS CATEGORIAS


N-1 variáveis!

UF
MG
SP
RJ
ES
MG
ES
SP
RJ
RJ
ES
MG
ES



UF_MG	UF_SP	UF_RJ
1	0	0
0	1	0
0	0	1
0	0	0
1	0	0
0	0	0
0	1	0
0	0	1
0	0	1
0	0	0
1	0	0
0	0	0

VARIÁVEIS DUMMY PARA MAIS DE DUAS CATEGORIAS



Como ficaria o Modelo de regressão ?

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{DUMMY_MG} + \hat{\beta}_2 X_{DUMMY_SP} + \hat{\beta}_3 X_{DUMMY_RJ} + e_i$$

- $\hat{\beta}_0$ representa o valor médio da variável resposta, para o ES
- A soma $\hat{\beta}_0 + \hat{\beta}_1$, representa o valor médio de y para MG
- A soma $\hat{\beta}_0 + \hat{\beta}_2$, , representa o valor médio de y para SP
- A soma $\hat{\beta}_0 + \hat{\beta}_3$, , representa o valor médio de y para RJ

ESCALONAMENTO

- É uma das transformações mais importantes ;
- A maioria dos algoritmos não funcionam bem quando **atributos numéricos de entrada tem escalas muito diferentes**
- Geralmente não é necessário escalonar os valores alvos ou target (Y)



NORMALIZAÇÃO: ESCALA MIN - MAX

- Os valores são deslocados e redimensionados para que variem entre 0 e 1

$$X_{normalizado} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- No *sklearn* possui um transformador chamado **MinMaxScaler**
- No *R* o *preprocess* do *caret*, *method = range*

PADRONIZAÇÃO

- Muito utilizada por ser bem mais sensível aos outliers.

$$Z = \frac{x - \mu}{\sigma}$$

- No **sklearn** possui um transformador chamado **StandardScaler**
- No R **scale**



PUC Minas
Virtual