

Modelos Lineares Generalizados

Anaíle Mendes Rabeo

Introdução aos Modelos Lineares Generalizados - GLM

Como selecionar o modelo correto ?

Anteriormente
estávamos
fixando um
modelo



Modelo Clássico
(Regressão
Linear)




Considera que
sua variável Y
segue uma dist.
Normal

Conhecemos o fenômeno aleatório gerador dos dados



Classificação de Variáveis Aleatórias



Variáveis discretas → suporte em um conjunto de valores enumeráveis (finitos ou infinitos)

Variáveis contínuas → suporte em um conjunto não enumerável de valores

Transformação de Box - Cox

Transforma o valor observado y , desde que esse valor seja positivo em:

$$z = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \text{para } \lambda \neq 0 \\ \log y, & \text{para } \lambda = 0 \end{cases}$$

Em que λ é uma constante conhecida.

Tem o objetivo de produzir aproximadamente a normalidade, variabilidade constante e a linearidade.

Essa média é igual a um η , onde ele será a combinação linear de nossas covariáveis.

$$E(Z) = \eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

Transformação de Box - Cox

As suposição não são atendidas.

A transformação NÃO será capaz de ajustar os dados


As suposição são atendidas

Temos um intervalo de valores de λ nas quais essas suposição é garantida

Antes dos computadores, os modelos de regressão eram aplicados mesmo quando a **distribuição da variável resposta não era normal**. Por exemplo, ao lidar com proporções, a distribuição normal era usada e transformações eram aplicadas para tentar ajustar os dados à normalidade.

Introdução

- ❑ A seleção de modelos é o procedimento mais importante na modelagem;
- ❑ A partir do modelo que realizaremos a inferência e predição
- ❑ Modelos parcimoniosos



Recapitulando o Modelos Lineares Clássicos

Pressupostos:


- $Y \sim N(\mu, \sigma^2)$;
- Aditividade do modelo;
- Homogeniedade das variâncias residuais;
- $e \sim N(0, \sigma^2)$;
- Resíduos independentes;

$$Y = \mu + \varepsilon$$

Onde:

- **Y**: vetor da variável resposta
- **$\mu = E(Y) = X\beta$** , **X**: Matriz de Dimensões
- **β** : Vetor de coeficientes
- **ε** : Componente aleatório

Fenômeno a ser estudado



Diagnóstico sobre Y

- Fundamental importância
- Elaborado antes da criação dos modelos
- Auxilia na escolha do melhor modelo

Origem dos GLM's

Criação de modelos para trabalhar com problemas específicos;

Modelos para dados qualitativos , qualitativos. Mesmo não seguindo distribuição Normal.

Pontos de convergência entre os modelos

Os modelos poderiam ser generalizados se utilizássemos uma função de ligação.

Nelder & Wedderburn (1975) propuseram uma teoria unificadora da modelagem estatística a que deram o nome de modelos lineares generalizados (GLM), como uma extensão dos modelos lineares classe


Surgimento dos GLM's

- Nelder & Wedderburn mostraram , que a maioria dos problemas estatísticos resolvidos por modelos de regressão podem ser generalizados pelo denominado “modelo linear generalizado”.
- Esses modelos envolvem uma variável resposta univariada , variáveis explicativas e uma amostra aleatória de n observações sendo que:
- Essa variável resposta , componente aleatório do modelo, **tem uma distribuição pertencente à família exponencial na forma canônica:**
 - distribuição normal, gama e normal inversa para dados contínuos;
 - binomial para proporções ; Poisson e binomial negativa para contagens.

COMPONENTES DE UM GLM


1° Componente

- Componente aleatório. Variável resposta (Y)
- segue uma distribuição que pertence à família exponencial.



2° Componente

- Componente sistemático
- É a parte fixa do modelo - as covariáveis (estrutura linear do nosso modelo)



3° Componente

- vai ligar o componente aleatório com o componente sistemático.
- Chamaremos de função de ligação(*link function*)

Identificando os componentes em um modelo clássico

$$Y = \mu + \varepsilon$$

Onde:

- **Y**: vetor da variável resposta
- **$\mu = E(Y) = X\beta$** , o componente sistemático
- **X**: Matriz de Dimensões
- **β** : Vetor de coeficientes
- **E**: Componente aleatório
- $Y \sim N(\mu, \sigma^2)$;

- Identificando a função de ligação : $g(\mu) = XB$
- No caso do modelo clássico a função de $g(\mu) = \mu$ (identidade)

DEFININDO O GLM ALGEBRICAMENTE

$$\eta = \alpha + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \dots + \hat{\beta}_n X_{ni} + e_i$$

Onde:

η : função de ligação canônica

α : representa a constante

$\hat{\beta}_1$ a $\hat{\beta}_k$: coeficientes de cada uma das variáveis independentes $X_{1i}, X_{2i}, \dots, X_{ni}$.

GLM'S E SUAS CARACTERÍSTICAS

Modelo	Característica de Y	Distribuição	Função de ligação Canônica (η)
Linear	Quantitativa	Normal	$\hat{Y}$
Logística binária	Qualitativa com 2 categorias (Dummy)	Bernoulli	$\ln\left(\frac{p}{1-p}\right)$
Logística Multinomial	Qualitativa com 3 ou mais categorias	Binomial	$\ln\left(\frac{p_m}{1-p_m}\right)$
Poisson	Quantitativa com dados de contagem	Poisson	$\ln(\lambda)$
Binomial Negativa	Quantitativa com dados de contagem	Poisson-gama	$\ln(\lambda)$

Especificações dos modelos lineares generalizados

Linear:

$$\hat{Y} = \alpha + \hat{\beta}_1 X_{1i} + \hat{\beta}_1 X_{2i} + \dots + \hat{\beta}_n X_{nn} + e_i$$

**Logística
Binária:**

$$\ln\left(\frac{p}{1-p}\right) = \alpha + \hat{\beta}_1 X_{1i} + \hat{\beta}_1 X_{2i} + \dots + \hat{\beta}_n X_{nn}$$

**Logística
Multinomial:**

$$\ln\left(\frac{p_m}{1-p_m}\right) = \alpha + \hat{\beta}_1 X_{1i} + \hat{\beta}_1 X_{2i} + \dots + \hat{\beta}_n X_{nn}$$

**Dados de
Contagem:**

$$\ln(\lambda) = \alpha + \hat{\beta}_1 X_{1i} + \hat{\beta}_1 X_{2i} + \dots + \hat{\beta}_n X_{nn}$$



PUC Minas
Virtual