




PUC Minas
Virtual

Estimação de Parâmetros

Ajuste dos GLM's




Introdução

Os GLM's possuem na prática **grande utilidade prática**:

- **Apresentam grande flexibilidade** na formulação do modelo: **computacionalmente simples**. Além de ser um modelo muito robusto é necessário poucas interações para conseguir a convergência dos parâmetros.
- Bons resultado a partir da Inferência : Analise de resíduos, de diagnósticos , da construção de intervalos de confiança e também dos testes de hipóteses.

Uma característica importante dos GLM's é que se **pressupõe independência das variáveis respostas** (ou, pelo menos, não correlacionadas)



Exemplo: dados de contagem -> modelo de Poisson (função logarítmica)

Na análise de resíduos temos que o modelo não está bem ajustado.

Podemos então pensar em modelos melhores dentro dessa classe de modelos de regressão . então isso é algo que é interessante dentro do ajuste dos GLM's

Seja um GLM definido pelos componentes aleatórios, sistemático e função de ligação. Suponha que as variáveis respostas, independentes, são representadas pelo vetor $\mathbf{y} = (y_1, \dots, y_n)^T$.

O logaritmo da função de verossimilhança com função de β (considerando-se o parâmetro de dispersão ϕ conhecido), é definido por especificado $\mathbf{y}$, é definido por $\ell(\beta) = \ell(\beta; \mathbf{y})$, dado por:


$$\ell(\beta) = \sum_{i=1}^n \ell_i(\theta_i, \phi, y_i) = \phi^{-1} \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^n c(y_i, \phi)$$

em que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \sum_{r=0}^p x_{ir} \beta_r$

Estimação dos Parâmetros

A partir do logaritmo da função de verossimilhança(β) considerando o parâmetro de dispersão conhecido.

Anteriormente na função exponencial tínhamos :




LOG

$$f(x; \theta; \phi) = \exp\{\phi^{-1}[y\theta - b(\theta)] + c(y, \phi)\}$$
$$\ell(\beta) = \sum_{i=1}^n \ell_i(\theta_i, \phi, y_i) = \phi^{-1} \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^n c(y_i, \phi)$$

em que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \sum_{r=0}^p x_{ir} \beta_r$

Em resumo



Algoritmo de Estimação

Vários métodos (qui-quadrado mínimo, Bayesiano e a estimação por MV) podem ser utilizados para estimar o vetor de parâmetros β .

Considerando o método de máximo verossimilhança para estimar os parâmetros lineares $\beta_0, \beta_1, \beta_2, \dots, \beta_n$ do modelo. Observa-se que o vetor escore é formado pelas derivas parciais de $\ell(\beta)$, isto é:

$$U_r = \frac{\partial \ell(\beta)}{\partial \beta_r} = \sum_{i=1}^n \frac{\partial \ell_i(\beta)}{\partial \beta_r} = 0$$

Algoritmo de Estimação

Estaremos derivando

$$\ell(\beta) = \sum_{i=1}^n \ell_i(\theta_i, \phi, y_i) = \phi^{-1} \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^n c(y_i, \phi)$$

$$\theta_i = q(\mu_i), \mu_i = g^{-1}(\eta_i) \text{ e } \eta_i = \sum_{r=0}^p x_{ir} \beta_r$$

Regra da Cadeia

$$U_r = \frac{\partial \ell(\beta)}{\partial \beta_r} = \frac{\partial \ell_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot \frac{\partial \eta_i}{\partial \beta_r}$$

Algoritmo de Estimação

Logo,

$$U_r = \frac{\partial \ell(\beta)}{\partial \beta_r} = \sum_{i=1}^n \frac{\partial \ell_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot \frac{\partial \eta_i}{\partial \beta_r}$$

$$\begin{array}{ccc} \ell(\beta) = f(\theta_1, \dots, \theta_i, \dots, \theta_n) & \xrightarrow{\hspace{1cm}} & \theta_i = \int V_i^{-1} d\mu_i = 1(\mu_i) \\ & & \downarrow \\ \eta_i = \sum_{r=0}^p x_{ir} \beta_r & \xleftarrow{\hspace{1cm}} & \mu_i = g^{-1}(\eta_i) = h(\eta_i) \end{array}$$

Algoritmo de Estimação

Sabendo-se que $\mu_i = b'(\theta_i)$ e $V(\mu_i) = \frac{\partial \mu_i}{\partial \theta_i}$

$$\begin{aligned} U_r &= \sum_{i=1}^n \frac{\partial \ell_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot \frac{\partial \eta_i}{\partial \beta_r} \\ &= \sum_{i=1}^n \frac{\partial \ell_i}{\partial \theta_i} \cdot \frac{1}{\frac{\partial \mu_i}{\partial \theta_i}} \cdot \frac{1}{\frac{\partial \eta_i}{\partial \mu_i}} \cdot \frac{\partial \eta_i}{\partial \beta_r} \end{aligned}$$

Algoritmo de Estimação

Sabendo que η_i é dado por:

$$\eta_i = \sum_{r=0}^p x_{ir} \beta_r = g(\mu_i)$$

η é exatamente a função de ligação, então se derivarmos o η_i em relação a μ_i estaríamos tomando a primeira derivada da função de ligação em relação a media, logo:

$$= \phi^{-1} \sum_{i=1}^n [y_i - b'(\theta_i)] \cdot \frac{1}{V(\mu_i)} \cdot \frac{1}{g'(\mu_i)} \cdot x_{ir}$$

Algoritmo de Estimação

Desmembrando a função temos que:

$$\frac{\partial \ell_i}{\partial \theta_i} = \phi^{-1} \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^n c(y_i, \phi) = \phi^{-1} \sum_{i=1}^n [y_i - b'(\theta_i)]$$

$$\frac{1}{\frac{\partial \mu_i}{\partial \theta_i}} = \frac{1}{V(\mu_i)}$$

A derivada do η_i em relação a i-ésimo parâmetro:

$$\frac{1}{\frac{\partial \eta_i}{\partial \mu_i}} = \frac{1}{g'(\mu_i)}$$

$$\eta_i = \sum_{r=0}^p x_{ir} \beta_r = x_{ir}$$

Algoritmo de Estimação

Ou seja, o vetor escore (U_r) pode ser escrito dessa maneira:

$$U_r = \phi^{-1} \sum_{i=1}^n [y_i - b'(\theta_i)] \cdot \frac{1}{V(\mu_i)} \cdot \frac{1}{g'(\mu_i)} \cdot x_{ir}$$

Ou então:

$$U_r = \phi^{-1} \sum_{i=1}^n \frac{(y_i - \mu_i) \cdot x_{ir}}{V(\mu_i) \cdot g'(\mu_i)}$$

Para $r = 0, 1, 2, \dots, p$

Algoritmo de Estimação

Problema



Não é uma equação linear

As estimativas de máximo verossimilhança não são dadas da forma explícita quando estamos trabalhando em um GLM

Métodos iterativos



PUC Minas
Virtual