

Estimação de Parâmetros: Método Escore de Fisher

Método de Newton-Raphson

Utilizando a versão multivariada do método de Newton- Raphson, obtém-se

$$\beta^{(m+1)} = \beta^{(m)} + (J^{(m)})^{-1} \cdot U^{(m)}$$

Em que $(J^{(m)})^{-1}$ é a inversa da matriz de informação observada de Fisher avaliada no passo m.

Observações:

1. Em geral as derivadas parciais na matriz J não são facilmente avaliadas.
2. Como alternativa podemos utilizar o método escore de Fisher , que consiste em substituir a **matriz de informação observada J pela matriz de informação esperada (K) de Fisher.**

Método Escore de Fisher

A diferença entre os métodos é que o escore de Fisher usa o valor esperado da matriz de informação de Fisher .

Utilizando o método escore de Fisher , temos que:

$$\beta^{(m+1)} = \beta^{(m)} + (\mathbf{K}^{(m)})^{-1} \cdot \mathbf{U}^{(m)}$$

Observe que anteriormente tínhamos a matriz $\mathbf{J}$, agora temos $\mathbf{K}$.

Sendo que $\mathbf{K}$ é a matriz de informação esperada de Fisher, expressa por:

$$\mathbf{K}_{r,s} = -E \left[\frac{\partial^2 \ell(\beta)}{\partial \beta_r \partial \beta_s} \right] = E \left[\frac{\partial \ell(\beta)}{\partial \beta_r} \cdot \frac{\partial \ell(\beta)}{\partial \beta_s} \right] = E[\mathbf{U}_r \cdot \mathbf{U}_s]$$

Método Escore de Fisher

Assim, multiplicando-se ambos os membros da equação por $\mathbf{K}^{(m)}$, tem-se

$$\mathbf{K}^{(m)} \cdot \boldsymbol{\beta}^{(m+1)} = \mathbf{K}^{(m)} \cdot \boldsymbol{\beta}^{(m)} + \mathbf{U}^{(m)}$$

$$U = \phi^{-1} \sum_{i=1}^n \frac{(y_i - \mu_i) \cdot x_{ir}}{V(\mu_i) \cdot g'(\mu_i)}$$

Observa-se que $K_{r,s}$ de $\mathbf{K}$ pode ser determinada por

$$K_{r,s} = E[U, U_s] = \phi^{-2} \sum_{i=1}^n \frac{E(Y_i - \mu_i)^2}{V^2(\mu_i) \cdot [g'(\mu_i)]^2} x_{ir} \cdot x_{is}$$

Método Escore de Fisher

E como $\text{Var}(Y_i) = E(Y_i - \mu_i)^2 = \phi \cdot V(\mu_i)$, obtém-se

$$K_{r,s} = \phi^{-2} \sum_{i=1}^n \frac{E(Y_i - \mu_i)^2}{V^2(\mu_i) \cdot [g'(\mu_i)]^2} x_{ir} \cdot x_{is} = \phi^{-1} \sum_{i=1}^n \omega_i x_{ir} \cdot x_{is}$$

Sendo

$$\omega_i = \frac{1}{V(\mu_i) \cdot [g'(\mu_i)]^2}$$

Denotado como função peso.

Método Escore de Fisher

Logo, a matriz de informação esperada de Fisher para β tem a forma

$$\mathbf{K} = \phi^{-1} \mathbf{X}^T \mathbf{W} \mathbf{X}$$

Em que $\mathbf{W} = \text{diag}\{\omega_1, \omega_2, \dots, \omega_n\}$ é uma matriz diagonal de pesos que capta a informação sobre a distribuição e a função de ligação utilizadas.

$$\mathbf{K}^{(m)} \cdot \beta^{(m+1)} = \mathbf{K}^{(m)} \cdot \beta^{(m)} + \mathbf{U}^{(m)}$$

Consequentemente,

$$U_r = \phi^{-1} \sum_{i=1}^n \frac{(y_i - \mu_i) \cdot x_{ir}}{V(\mu_i) \cdot g'(\mu_i)}$$

Método Escore de Fisher

$$U_r = \phi^{-1} \sum_{i=1}^n \frac{(y_i - \mu_i) \cdot x_{ir}}{V(\mu_i) \cdot g'(\mu_i)} = \phi^{-1} \sum_{i=1}^n \frac{(y_i - \mu_i) \cdot g'(\mu_i)}{V(\mu_i) \cdot [g'(\mu_i)]^2} \cdot x_{ir}$$

Considerando:

$$\omega_i = \frac{1}{V(\mu_i) \cdot [g'(\mu_i)]^2}$$

$$= \phi^{-1} \sum_{i=1}^n \omega_i \cdot g'(\mu_i) \cdot (y_i - \mu_i) \cdot x_{ir}$$

Método Escore de Fisher

Portanto, o vetor escore U pode ser representado por:

$$U = \phi^{-1} \mathbf{X}^T \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$$

Em que $\mathbf{G} = \text{diag}\{g'(\mu_1), \dots, g'(\mu_i)\}$ é uma matriz diagonal formada pelas derivadas de 1ª ordem da função de ligação.

Substituindo $\mathbf{K}$ e $\mathbf{U}$ em (1), temos que:

$$\mathbf{X}^T \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \mathbf{X}^T \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m)} + \mathbf{X}^T \mathbf{W}^{(m)} \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)})$$

Método Escore de Fisher

Colocando em evidencia o $\mathbf{X}^T \mathbf{W}^{(m)}$

$$\mathbf{X}^T \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \mathbf{X}^T \mathbf{W}^{(m)} [\mathbf{X} \boldsymbol{\beta}^{(m)} + \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)})]$$

Sabemos que $\mathbf{X} \boldsymbol{\beta}^{(m)}$ que é nosso preditor linear

$$\mathbf{X}^T \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \mathbf{X}^T \mathbf{W}^{(m)} [\boldsymbol{\eta}^{(m)} + \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)})]$$

Em que:

$$\mathbf{z} = \boldsymbol{\eta}^{(m)} + \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)})$$

é a variável dependente ajustada.

Método Escore de Fisher

Logo

$$\mathbf{X}^T \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \mathbf{X}^T \mathbf{W}^{(m)} \cdot \mathbf{z}^{(m)}$$

Portanto o algoritmo da estimação para os GLM's é representado por:

$$\boldsymbol{\beta}^{(m+1)} = (\mathbf{X}^T \mathbf{W}^{(m)} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{(m)} \cdot \mathbf{z}^{(m)}$$

Observações

1. O algoritmo de estimação é válido para qualquer GLM;
2. A estimação por máxima verossimilhança, em GLM, requer que os recursos computacionais produzam estimativa do método de mínimos quadrados ponderados (pela média / peso);
3. A equação iterativa não depende do parâmetro de dispersão ϕ ;
4. Para iniciar o processo iterativo temos que especificar uma estimativa inicial e, alterá-la até que a convergência seja alcançada.

1 – Note, contudo, que cada observação pode ser considerada como uma estimativa do seu valor médio, isto é $\mu_i^{(0)} = y_i$ e, assim, calcula-se

$$\eta_i^{(0)} = g\left(\mu_i^{(0)}\right) = g(y_i)$$

2 – Calcula-se os elementos do vetor z e a matriz W com base nos valores μ_i atribuídos no passo anterior:

$$z_i^{(0)} = \eta_i^{(0)} + \left(y_i - \mu_i^{(0)}\right) \cdot g(\mu_i^{(0)})$$

E

$$\omega_i = \frac{1}{V(\mu_i^{(0)}) \cdot [g'(\mu_i^{(0)})]^2}$$

Um critério de convergência que pode ser considerado é o seguinte:

$$\sum_{r=0}^p \left(\frac{\beta_r^{(m+1)} - \beta_r^{(m)}}{\beta_r^{(m)}} \right)^2 < \varepsilon$$

Em que $\varepsilon > 0$ suficientemente pequeno. Em geral esse **algoritmo é robusto e converge rapidamente** (menos de 10 iterações são suficientes).



PUC Minas
Virtual