

Apredizado de Máquina e Reconhecimento de Padrões

– Conceitos Básicos / Teoria da Decisão –

Zenilton Kleber Gonçalves do Patrocínio Jr.

Programa Pós-graduação em Informática – PUC Minas

Belo Horizonte, Brasil

2017



Roteiro




- 1 Introdução a Aprendizado de Máquina
- 2 Performance
- 3 Treino x Teste
- 4 Comparação Experimental
- 5 Teoria de Decisão

Aprendizado de Máquina


VIP LAB




Aprendizado de Máquina



Aprendizado de Máquina



Aprendizado de Máquina




Aprendizado de Máquina



*Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)*

<http://demo.caffe.berkeleyvision.org/>



Aprendizado de Máquina



Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)

<http://demo.caffe.berkeleyvision.org/>

The screenshot shows a web browser window titled "Caffe Demos" with the URL http://demo.caffe.berkeleyvision.org/classify_url?imageurl=http%3A%2F%2F1.lelograph.cc.uk%2Fres%2Fmedia%2Farchive%2F0223%2Fcross-eyed-. The page has a header "Caffe Demos" and a sub-header "The Caffe neural network library makes implementing state-of-the-art computer vision systems easy." Below this is a "Classification" section with a link "Click for a Quick Example". A small image of a cat is shown on the left. To the right, there are two tabs: "Maximally accurate" (selected) and "Maximally specific". Below the tabs is a table of classification results:

cat	1.7959
feline	1.1429
domestic cat	1.7155
tabby	0.9548
domestic animal	0.7745

Below the table, it says "CNN took 0.067 seconds." At the bottom, there is a form to "Provide an image URL" with a "Classify URL" button, and a section for "Or upload an image:" with a "Procurar..." button. The footer says "© BVLC 2014".

Aprendizado de Máquina



*Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)*

<http://demo.caffe.berkeleyvision.org/>

The screenshot shows the 'Caffe Demos' web interface. At the top, it says 'Caffe Demos' and 'The Caffe neural network library makes implementing state-of-the-art computer vision systems easy.' Below this, the 'Classification' section is active. It shows a small image of an aircraft and a list of classification results with their confidence scores:

Classification	Score
heavier-than-air craft	0.96702
craft	0.95590
aircraft	0.91907
vehicle	0.84120
wing	0.78730

Below the results, it states 'CNN took 0.065 seconds.' At the bottom, there is a form to 'Provide an image URL' or 'upload an image' with a 'Classify URL' button and a 'Choose...' button for image upload.

Aprendizado de Máquina



Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)

<http://demo.caffe.berkeleyvision.org/>

The screenshot shows the Caffe Demos web interface in a browser window. The page title is "Caffe Demos" and it includes a brief description: "The Caffe neural network library makes implementing state-of-the-art computer vision systems easy." Under the "Classification" section, there is a "Click for a Quick Example" link. Below this is a small image of horses in a field. To the right of the image, there are two tabs: "Maximally accurate" (selected) and "Maximally specific". A list of classification results is shown with their corresponding confidence scores in parentheses:

Classification	Score
sorrel	(1.99067)
horse	(1.98835)
equine	(1.74472)
odd-toed ungulate	(1.71522)
ungulate	(1.70796)

Below the results, it states "CNN took 0.068 seconds." At the bottom, there is a form to "Provide an image URL" with a "Classify URL" button, and an option to "Or upload an image:" with a "Choose..." button. The footer indicates "© BVLC 2014".

Aprendizado de Máquina



*Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)*

<http://demo.caffe.berkeleyvision.org/>

Caffe Demos

The Caffe neural network library makes implementing state-of-the-art computer vision systems easy.

Classification

[Click for a Quick Example](#)

Maximally accurate | Maximally specific

cart	1.84851
wagon	1.81969
horse cart	1.20223
wheeled vehicle	1.09991
vehicle	0.91372

CNN took 0.066 seconds.

Provide an image URL:

Or upload an image:

© BVLC 2014

Aprendizado de Máquina



*Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)*

<http://demo.caffe.berkeleyvision.org/>

The screenshot shows the 'Caffe Demos' web interface. It features a 'Classification' section with a 'Click for a Quick Example' link. An image of a horse cart is shown on the left. To the right, there are two tabs: 'Maximally accurate' and 'Maximally specific'. Below these, a list of classification results is displayed with corresponding confidence scores:

Classification	Score
cart	1.84851
wagon	1.81969
horse cart	1.20223
wheeled vehicle	1.09991
vehicle	0.91372

Below the results, it states 'CNN took 0.066 seconds.' At the bottom, there is a form to 'Provide an image URL' and a 'Classify URL' button, and another section for 'Or upload an image:' with a 'Procurar...' button. The footer indicates '© BVLC 2014'.

Aprendizado de Máquina



*Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)*

<http://demo.caffe.berkeleyvision.org/>

Caffe Demos

The Caffe neural network library makes implementing state-of-the-art computer vision systems easy.

Classification

[Click for a Quick Example](#)



Maximally accurate

Maximally specific

dog	0.84577
domestic animal	0.76990
canine	0.75496
hunting dog	0.74730
even-toed ungulate	0.63268

CNN took 0.101 seconds.

Provide an image URL [Classify URL](#)

Or upload an image: [Browse...](#)

© BVLC 2014

Aprendizado de Máquina



*Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)*

<http://demo.caffe.berkeleyvision.org/>

Caffe Demos

The Caffe neural network library makes implementing state-of-the-art computer vision systems easy.

Classification

[Click for a Quick Example](#)



Maximally accurate	Maximally specific
dog	0.84577
domestic animal	0.76990
canine	0.75406
hunting dog	0.74730
even-toed ungulate	0.63268

CNN took 0.101 seconds.

Provide an image URL

Or upload an image:


© BVLC 2014

Aprendizado de Máquina



*Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)*

<http://demo.caffe.berkeleyvision.org/>



Aprendizado de Máquina



Berkeley Vision and Learning Center: **Caffe** (Deep learning framework)

<http://demo.caffe.berkeleyvision.org/>

The screenshot shows the 'Caffe Demos' web interface. It features a 'Classification' section with a photo of a man. A red box highlights the classification results, which are listed in a table below. The table has two columns: 'Maximally accurate' and 'Maximally specific'. The results are as follows:

Maximally accurate	Maximally specific
clothing	0.47730
covering	0.46980
consumer goods	0.43249
commodity	0.41837
ball	0.31895

Below the table, it states 'CNN took 0.063 seconds.' At the bottom, there is a form to 'Provide an image URL' and a 'Classify URL' button, and another section to 'Or upload an image:' with a 'Browse...' button.

Aprendizado de Máquina



Classes

Aprendizado supervisionado lida com a atribuição de rótulos a um conjunto de objetos pertencentes a diferentes classes.

Uma classe contém objetos similares, ao passo que objetos de classes distintas devem ser dissimilares.

Dado um conjunto de c classes com rótulos $\Omega = \{\omega_1, \omega_2, \dots, \omega_c\}$, sendo que cada objeto pertence a uma única classe.

Dado um conjunto de $p + q$ objetos $\mathcal{O} = \{o_1, o_2, \dots, o_p, \dots, o_{p+q}\}$ em que $C(o_i)$ representa a classe a que pertence o objeto i , $\forall i = 1, \dots, p$, busca-se determinar $C(o_j)$, $\forall j = p + 1, \dots, p + q$.

Aprendizado de Máquina



Classes

Aprendizado supervisionado lida com a atribuição de rótulos a um conjunto de objetos pertencentes a diferentes classes.

Uma classe contém objetos similares, ao passo que objetos de classes distintas devem ser dissimilares.

Dado um conjunto de c classes com rótulos $\Omega = \{\omega_1, \omega_2, \dots, \omega_c\}$, sendo que cada objeto pertence a uma única classe.

Dado um conjunto de $p + q$ objetos $\mathcal{O} = \{o_1, o_2, \dots, o_p, \dots, o_{p+q}\}$ em que $C(o_i)$ representa a classe a que pertence o objeto $i, \forall i = 1, \dots, p$, busca-se determinar $C(o_j), \forall j = p + 1, \dots, p + q$.

Aprendizado de Máquina



Classes

Aprendizado supervisionado lida com a atribuição de rótulos a um conjunto de objetos pertencentes a diferentes classes.

Uma classe contém objetos similares, ao passo que objetos de classes distintas devem ser dissimilares.

Dado um conjunto de c classes com rótulos $\Omega = \{\omega_1, \omega_2, \dots, \omega_c\}$, sendo que cada objeto pertence a uma única classe.

Dado um conjunto de $p + q$ objetos $\mathcal{O} = \{o_1, o_2, \dots, o_p, \dots, o_{p+q}\}$ em que $C(o_i)$ representa a classe a que pertence o objeto $i, \forall i = 1, \dots, p$, busca-se determinar $C(o_j), \forall j = p + 1, \dots, p + q$.

Aprendizado de Máquina



Classes

Aprendizado supervisionado lida com a atribuição de rótulos a um conjunto de objetos pertencentes a diferentes classes.

Uma classe contém objetos similares, ao passo que objetos de classes distintas devem ser dissimilares.

Dado um conjunto de c classes com rótulos $\Omega = \{\omega_1, \omega_2, \dots, \omega_c\}$, sendo que cada objeto pertence a uma única classe.


Dado um conjunto de $p + q$ objetos $\mathcal{O} = \{o_1, o_2, \dots, o_p, \dots, o_{p+q}\}$ em que $C(o_i)$ representa a classe a que pertence o objeto i , $\forall i = 1, \dots, p$, busca-se determinar $C(o_j)$, $\forall j = p + 1, \dots, p + q$.

Aprendizado de Máquina



Características

Objetos são descritos por uma série de características (ou atributos).




Aprendizado de Máquina



Características

Objetos são descritos por uma série de características (ou atributos).



Aprendizado de Máquina



Espaço de Características

As características de um dado objeto são organizadas em um vetor $\mathbf{x} = [x_1, x_2, \dots, x_n]^T \in \mathbb{R}^n$ – chamado de espaço de características em que cada eixo corresponde a uma característica específica.

Características qualitativas devem ser convertidas em quantitativas – geralmente, por meio de técnicas heurísticas e altamente subjetivas.

Kittler et al. (1998) propõem a *distinct pattern representation* em que se formam subvetores para subconjuntos de características relacionadas com modalidades diferentes

$$\mathbf{x} = [x^{(1)}, x^{(2)}, \dots, x^{(M)}]^T, x^{(m)} \in \mathbb{R}^{n_m}, m = 1, \dots, M.$$

Aprendizado de Máquina



Espaço de Características

As características de um dado objeto são organizadas em um vetor $\mathbf{x} = [x_1, x_2, \dots, x_n]^T \in \mathbb{R}^n$ – chamado de espaço de características em que cada eixo corresponde a uma característica específica.

Características qualitativas devem ser convertidas em quantitativas – geralmente, por meio de técnicas heurísticas e altamente subjetivas.

Kittler et al. (1998) propõem a *distinct pattern representation* em que se formam subvetores para subconjuntos de características relacionadas com modalidades diferentes

$$\mathbf{x} = [x^{(1)}, x^{(2)}, \dots, x^{(M)}]^T, x^{(m)} \in \mathbb{R}^{n_m}, m = 1, \dots, M.$$

Aprendizado de Máquina



Espaço de Características

As características de um dado objeto são organizadas em um vetor $\mathbf{x} = [x_1, x_2, \dots, x_n]^T \in \mathbb{R}^n$ – chamado de espaço de características em que cada eixo corresponde a uma característica específica.

Características qualitativas devem ser convertidas em quantitativas – geralmente, por meio de técnicas heurísticas e altamente subjetivas.

Kittler et al. (1998) propõem a *distinct pattern representation* em que se formam subvetores para subconjuntos de características relacionadas com modalidades diferentes

$$\mathbf{x} = [x^{(1)}, x^{(2)}, \dots, x^{(M)}]^T, x^{(m)} \in \mathbb{R}^{n_m}, m = 1, \dots, M.$$

Aprendizado de Máquina



Conjunto de Dados

As informações utilizadas no projeto de um classificador estão geralmente sob a forma de um conjunto de dados rotulado $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_N]$, $\mathbf{z}_j \in \mathbb{R}^n$. O rótulo indicando a classe de $\mathbf{z}_j$ é representado por $y_j \in \Omega$, $j = 1, \dots, N$.

Um “típico” conjunto de dados pode ser organizado como uma matriz com N linhas (objetos ou instâncias) por n colunas (características), com uma coluna (ou vetor) extra contendo os rótulos das classes.

$$\text{Conjunto} = \begin{bmatrix} z_{11} & z_{12} & \cdots & z_{1n} \\ z_{21} & z_{22} & \cdots & z_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ z_{N1} & z_{N2} & \cdots & z_{Nn} \end{bmatrix} \quad \text{Rótulos} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

Aprendizado de Máquina



Conjunto de Dados

As informações utilizadas no projeto de um classificador estão geralmente sob a forma de um conjunto de dados rotulado $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_N]$, $\mathbf{z}_j \in \mathbb{R}^n$. O rótulo indicando a classe de $\mathbf{z}_j$ é representado por $y_j \in \Omega, j = 1, \dots, N$.

Um “típico” conjunto de dados pode ser organizado como uma matriz com N linhas (objetos ou instâncias) por n colunas (características), com uma coluna (ou vetor) extra contendo os rótulos das classes.

$$\text{Conjunto} = \begin{bmatrix} z_{11} & z_{12} & \cdots & z_{1n} \\ z_{21} & z_{22} & \cdots & z_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ z_{N1} & z_{N2} & \cdots & z_{Nn} \end{bmatrix} \quad \text{Rótulos} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

Aprendizado de Máquina




Conjunto de Dados

As informações utilizadas no projeto de um classificador estão geralmente sob a forma de um conjunto de dados rotulado $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_N]$, $\mathbf{z}_j \in \mathbb{R}^n$. O rótulo indicando a classe de $\mathbf{z}_j$ é representado por $y_j \in \Omega, j = 1, \dots, N$.

Um “típico” conjunto de dados pode ser organizado como uma matriz com N linhas (objetos ou instâncias) por n colunas (características), com uma coluna (ou vetor) extra contendo os rótulos das classes.

$$\text{Conjunto} = \begin{bmatrix} z_{11} & z_{12} & \cdots & z_{1n} \\ z_{21} & z_{22} & \cdots & z_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ z_{N1} & z_{N2} & \cdots & z_{Nn} \end{bmatrix} \quad \text{Rótulos} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

Aprendizado de Máquina



Aprendizado de Máquina



Distribuição de Objetos por Classe

Object	$\triangle$	$\square$	$\bigcirc$	$\blacktriangle$	$\blacksquare$	$\bullet$
Class ω_1	9	22	72	1	4	20
Class ω_2	4	25	5	8	79	7
Decision	ω_1	ω_2	ω_1	ω_2	ω_2	ω_1

Com base na distribuição dos dados, faz sentido escolher a classe ω_1 se tivermos um círculo (de qualquer cor) ou um triângulo branco; caso contrário, deve-se escolher a classe ω_2 .

Assim, essas duas características resultam em 43 erros ($\approx 16,8\%$).

Aprendizado de Máquina



Distribuição de Objetos por Classe

Object	$\triangle$	$\square$	$\bigcirc$	$\blacktriangle$	$\blacksquare$	$\bullet$
Class ω_1	9	22	72	1	4	20
Class ω_2	4	25	5	8	79	7
Decision	ω_1	ω_2	ω_1	ω_2	ω_2	ω_1

Com base na distribuição dos dados, faz sentido escolher a classe ω_1 se tivermos um círculo (de qualquer cor) ou um triângulo branco; caso contrário, deve-se escolher a classe ω_2 .

Assim, essas duas características resultam em 43 erros ($\approx 16,8\%$).

Aprendizado de Máquina



Distribuição de Objetos por Classe

Object	$\triangle$	$\square$	$\bigcirc$	$\blacktriangle$	$\blacksquare$	$\bullet$
Class ω_1	9	22	72	1	4	20
Class ω_2	4	25	5	8	79	7
Decision	ω_1	ω_2	ω_1	ω_2	ω_2	ω_1

Com base na distribuição dos dados, faz sentido escolher a classe ω_1 se tivermos um círculo (de qualquer cor) ou um triângulo branco; caso contrário, deve-se escolher a classe ω_2 .

Assim, essas duas características resultam em 43 erros ($\approx 16,8\%$).

Aprendizado de Máquina



Classificador

Um classificador é qualquer função D capaz de atribuir um rótulo de classe a um dado objeto, isto é, $D : \mathbb{R}^n \mapsto \Omega$.

Função Discriminante

Segundo Dutta e Hart (1973), em um *modelo canônico de classificador*, c funções discriminantes $g_i : \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, c$, são calculadas em que cada uma fornece uma pontuação ou “score” para a respectiva classe.

Geralmente (e, mais naturalmente) um objeto $\mathbf{x} \in \mathbb{R}^n$ é rotulado com a classe de maior pontuação. Essa escolha é chamada de “*maximum membership rule*”, ou ainda,

$$D(\mathbf{x}) = \omega_{i^*} \in \Omega \iff g_{i^*} = \max_{i=1,\dots,c} \{g_i(\mathbf{x})\}$$

Aprendizado de Máquina



Classificador

Um classificador é qualquer função D capaz de atribuir um rótulo de classe a um dado objeto, isto é, $D : \mathbb{R}^n \mapsto \Omega$.

Função Discriminante

Segundo Dutta e Hart (1973), em um *modelo canônico de classificador*, c funções discriminantes $g_i : \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, c$, são calculadas em que cada uma fornece uma pontuação ou “score” para a respectiva classe.

Geralmente (e, mais naturalmente) um objeto $\mathbf{x} \in \mathbb{R}^n$ é rotulado com a classe de maior pontuação. Essa escolha é chamada de “*maximum membership rule*”, ou ainda,

$$D(\mathbf{x}) = \omega_{i^*} \in \Omega \iff g_{i^*} = \max_{i=1,\dots,c} \{g_i(\mathbf{x})\}$$

Aprendizado de Máquina



Classificador

Um classificador é qualquer função D capaz de atribuir um rótulo de classe a um dado objeto, isto é, $D : \mathbb{R}^n \mapsto \Omega$.

Função Discriminante

Segundo Dutta e Hart (1973), em um *modelo canônico de classificador*, c funções discriminantes $g_i : \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, c$, são calculadas em que cada uma fornece uma pontuação ou “score” para a respectiva classe.


Geralmente (e, mais naturalmente) um objeto $\mathbf{x} \in \mathbb{R}^n$ é rotulado com a classe de maior pontuação. Essa escolha é chamada de “*maximum membership rule*”, ou ainda,

$$D(\mathbf{x}) = \omega_{i^*} \in \Omega \iff g_{i^*} = \max_{i=1,\dots,c} \{g_i(\mathbf{x})\}$$

Aprendizado de Máquina



Modelo Canônico de Classificador



Região de Classificação


As funções discriminantes particionam o espaço de características $\mathbb{R}^n$ em c regiões de decisão ou regiões de classificação (não necessariamente compactas) representadas por $\mathcal{R}_1, \dots, \mathcal{R}_c$ em que

$$\mathcal{R}_i = \left\{ \mathbf{x} \mid \mathbf{x} \in \mathbb{R}^n, g_i = \max_{k=1, \dots, c} g_k(\mathbf{x}) \right\}, i = 1, \dots, c.$$

Aprendizado de Máquina



Modelo Canônico de Classificador



Região de Classificação

As funções discriminantes particionam o espaço de características $\mathbb{R}^n$ em c regiões de decisão ou regiões de classificação (não necessariamente compactas) representadas por $\mathcal{R}_1, \dots, \mathcal{R}_c$ em que

$$\mathcal{R}_i = \left\{ \mathbf{x} \mid \mathbf{x} \in \mathbb{R}^n, g_i = \max_{k=1, \dots, c} g_k(\mathbf{x}) \right\}, i = 1, \dots, c.$$

Aprendizado de Máquina



Fronteira de Classificação

As fronteiras entre regiões de decisão são chamadas fronteiras de classificação e elas contêm os pontos para os quais há um empate de funções discriminantes com maior pontuação (ou “score”). Um ponto na fronteira pode ser atribuído a qualquer das classes fronteiriças.

Classes Sobrepostas

Se uma região de decisão $\mathcal{R}_i$ possuir pontos do conjunto de dados $\mathbf{Z}$ cujos rótulos verdadeiros são $\omega_j, j \neq i$, as classes ω_i e ω_j são ditas sobrepostas.

Classes sobrepostas em um dado particionamento pode não se sobrepor caso o espaço seja dividido de forma diferente.

Se não existir nenhum ponto idêntico com diferentes rótulos no conjunto de dados $\mathbf{Z}$, sempre se pode particionar o espaço de características em regiões de classificação sem sobreposição.

Aprendizado de Máquina



Fronteira de Classificação

As fronteiras entre regiões de decisão são chamadas fronteiras de classificação e elas contêm os pontos para os quais há um empate de funções discriminantes com maior pontuação (ou “score”). Um ponto na fronteira pode ser atribuído a qualquer das classes fronteiriças.

Classes Sobrepostas

Se uma região de decisão $\mathcal{R}_i$ possuir pontos do conjunto de dados $\mathbf{Z}$ cujos rótulos verdadeiros são $\omega_j, j \neq i$, as classes ω_i e ω_j são ditas sobrepostas.

Classes sobrepostas em um dado particionamento pode não se sobrepor caso o espaço seja dividido de forma diferente.

Se não existir nenhum ponto idêntico com diferentes rótulos no conjunto de dados $\mathbf{Z}$, sempre se pode particionar o espaço de características em regiões de classificação sem sobreposição.

Aprendizado de Máquina



Fronteira de Classificação

As fronteiras entre regiões de decisão são chamadas fronteiras de classificação e elas contêm os pontos para os quais há um empate de funções discriminantes com maior pontuação (ou “score”). Um ponto na fronteira pode ser atribuído a qualquer das classes fronteiriças.

Classes Sobrepostas

Se uma região de decisão $\mathcal{R}_i$ possuir pontos do conjunto de dados $\mathbf{Z}$ cujos rótulos verdadeiros são $\omega_j, j \neq i$, as classes ω_i e ω_j são ditas sobrepostas.

Classes sobrepostas em um dado particionamento pode não se sobrepor caso o espaço seja dividido de forma diferente.

Se não existir nenhum ponto idêntico com diferentes rótulos no conjunto de dados $\mathbf{Z}$, sempre se pode particionar o espaço de características em regiões de classificação sem sobreposição.

Aprendizado de Máquina



Fronteira de Classificação

As fronteiras entre regiões de decisão são chamadas fronteiras de classificação e elas contêm os pontos para os quais há um empate de funções discriminantes com maior pontuação (ou “score”). Um ponto na fronteira pode ser atribuído a qualquer das classes fronteiriças.

Classes Sobrepostas

Se uma região de decisão $\mathcal{R}_i$ possuir pontos do conjunto de dados $\mathbf{Z}$ cujos rótulos verdadeiros são $\omega_j, j \neq i$, as classes ω_i e ω_j são ditas sobrepostas.



Classes sobrepostas em um dado particionamento pode não se sobrepor caso o espaço seja dividido de forma diferente.

Se não existir nenhum ponto idêntico com diferentes rótulos no conjunto de dados $\mathbf{Z}$, sempre se pode particionar o espaço de características em regiões de classificação sem sobreposição.

Aprendizado de Máquina



Fronteiras de Classificação





Qualquer conjunto de funções $g_1(x), \dots, g_c(x)$ pode ser um conjunto de funções discriminantes mas não necessariamente separam as classes de forma adequada.

Aprendizado de Máquina



Fronteiras de Classificação



Qualquer conjunto de funções $g_1(\mathbf{x}), \dots, g_c(\mathbf{x})$ pode ser um conjunto de funções discriminantes mas não necessariamente separam as classes de forma adequada.

Aprendizado de Máquina




Exemplo de Função Discriminante Linear

Para duas classes, pode-se usar apenas uma função discriminante, por exemplo:

$$g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x}) \begin{cases} \geq 0, & \text{se } \mathbf{x} \in \mathcal{R}_1 \\ < 0, & \text{se } \mathbf{x} \in \mathcal{R}_2 \end{cases}$$

Exemplo de função discriminante linear: $g(x) = -7x_1 + 4x_2 + 21$



Performance de Classificadores



Performance

Performance de um classificador é consequência de diversos fatores cujo componente mais importante é a acurácia de classificação.

De modo a obter de maneira exata o valor da acurácia de um classificador, seria necessário que se avaliasse o mesmo sobre todos os objetos de entrada possíveis. Como geralmente esse cenário não é viável, deve-se utilizar uma estimativa do valor da acurácia.

O erro de classificação é uma característica dual em relação à acurácia, de modo que esses dois valores somam sempre 1

$$\text{Erro} = 1 - \text{Acurácia}$$

O valor que interessa é chamado erro de generalização e é equivalente ao erro esperado da aplicação de um classificador treinado sobre dados desconhecidos obtidos a partir da distribuição associada ao problema.

Performance de Classificadores



Performance

Performance de um classificador é consequência de diversos fatores cujo componente mais importante é a acurácia de classificação.

De modo a obter de maneira exata o valor da acurácia de um classificador, seria necessário que se avaliasse o mesmo sobre todos os objetos de entrada possíveis. Como geralmente esse cenário não é viável, deve-se utilizar uma estimativa do valor da acurácia.

O erro de classificação é uma característica dual em relação à acurácia, de modo que esses dois valores somam sempre 1

$$\text{Erro} = 1 - \text{Acurácia}$$

O valor que interessa é chamado erro de generalização e é equivalente ao erro esperado da aplicação de um classificador treinado sobre dados desconhecidos obtidos a partir da distribuição associada ao problema.

Performance de Classificadores



Performance

Performance de um classificador é consequência de diversos fatores cujo componente mais importante é a acurácia de classificação.

De modo a obter de maneira exata o valor da acurácia de um classificador, seria necessário que se avaliasse o mesmo sobre todos os objetos de entrada possíveis. Como geralmente esse cenário não é viável, deve-se utilizar uma estimativa do valor da acurácia.

O erro de classificação é uma característica dual em relação à acurácia, de modo que esses dois valores somam sempre 1

$$\text{Erro} = 1 - \text{Acurácia}$$

O valor que interessa é chamado erro de generalização e é equivalente ao erro esperado da aplicação de um classificador treinado sobre dados desconhecidos obtidos a partir da distribuição associada ao problema.

Performance de Classificadores



Performance

Performance de um classificador é consequência de diversos fatores cujo componente mais importante é a acurácia de classificação.

De modo a obter de maneira exata o valor da acurácia de um classificador, seria necessário que se avaliasse o mesmo sobre todos os objetos de entrada possíveis. Como geralmente esse cenário não é viável, deve-se utilizar uma estimativa do valor da acurácia.

O erro de classificação é uma característica dual em relação à acurácia, de modo que esses dois valores somam sempre 1

$$\text{Erro} = 1 - \text{Acurácia}$$

O valor que interessa é chamado erro de generalização e é equivalente ao erro esperado da aplicação de um classificador treinado sobre dados desconhecidos obtidos a partir da distribuição associada ao problema.

Performance de Classificadores



Erro de Generalização

O erro de generalização E_G de um classificador D treinado com um conjunto de dados $\mathbf{Z}$ pode ser decomposto da seguinte forma:

$$E_G(D, \mathbf{Z}) = E_A(\mathbf{Z}) + E_M + E_B$$

$E_A(\mathbf{Z})$ representa o erro de aproximação devido a variância em virtude do uso de diferentes dados de treinamento e/ou de algoritmos “sub-ótimos” e não-determinísticos para treino do classificador. (*model variance*)

E_M representa o erro de modelagem relacionado o fato da melhor solução para um dado espaço de características não poder ser alcançada pelo modelo de classificador utilizado. (*model bias*)

E_B representa o erro de representação (*Bayes error*) devido ao fato das características disponíveis não serem suficientes ou adequadas para separação das classes de forma correta (representação insuficiente).

Performance de Classificadores



Erro de Generalização

O erro de generalização E_G de um classificador D treinado com um conjunto de dados $\mathbf{Z}$ pode ser decomposto da seguinte forma:

$$E_G(D, \mathbf{Z}) = E_A(\mathbf{Z}) + E_M + E_B$$

$E_A(\mathbf{Z})$ representa o erro de aproximação devido a variância em virtude do uso de diferentes dados de treinamento e/ou de algoritmos “sub-ótimos” e não-determinísticos para treino do classificador. (*model variance*)

E_M representa o erro de modelagem relacionado o fato da melhor solução para um dado espaço de características não poder ser alcançada pelo modelo de classificador utilizado. (*model bias*)

E_B representa o erro de representação (*Bayes error*) devido ao fato das características disponíveis não serem suficientes ou adequadas para separação das classes de forma correta (representação insuficiente).

Performance de Classificadores



Erro de Generalização

O erro de generalização E_G de um classificador D treinado com um conjunto de dados $\mathbf{Z}$ pode ser decomposto da seguinte forma:

$$E_G(D, \mathbf{Z}) = E_A(\mathbf{Z}) + E_M + E_B$$

$E_A(\mathbf{Z})$ representa o erro de aproximação devido a variância em virtude do uso de diferentes dados de treinamento e/ou de algoritmos “sub-ótimos” e não-determinísticos para treino do classificador. (*model variance*)

E_M representa o erro de modelagem relacionado o fato da melhor solução para um dado espaço de características não poder ser alcançada pelo modelo de classificador utilizado. (*model bias*)

E_B representa o erro de representação (*Bayes error*) devido ao fato das características disponíveis não serem suficientes ou adequadas para separação das classes de forma correta (representação insuficiente).

Performance de Classificadores



Erro de Generalização

O erro de generalização E_G de um classificador D treinado com um conjunto de dados $\mathbf{Z}$ pode ser decomposto da seguinte forma:

$$E_G(D, \mathbf{Z}) = E_A(\mathbf{Z}) + E_M + E_B$$

$E_A(\mathbf{Z})$ representa o erro de aproximação devido a variância em virtude do uso de diferentes dados de treinamento e/ou de algoritmos “sub-ótimos” e não-determinísticos para treino do classificador. (*model variance*)


E_M representa o erro de modelagem relacionado o fato da melhor solução para um dado espaço de características não poder ser alcançada pelo modelo de classificador utilizado. (*model bias*)

E_B representa o erro de representação (*Bayes error*) devido ao fato das características disponíveis não serem suficientes ou adequadas para separação das classes de forma correta (representação insuficiente).

Performance de Classificadores



Erro de Generalização




- 1: Our solution
- 2: Best possible solution with the chosen model
- 3: Best possible solution with the available features
- 4: The "real thing"

Performance de Classificadores




Bias × *Variance*

Low bias, high variance



High bias, low variance



Performance de Classificadores



Cálculo do Erro

Considere que um conjunto de dados rotulados $\mathbf{Z}_{ts}$ de tamanho $N_{ts} \times n$ está disponível obtenção da acurácia. Uma forma natural de se calcular uma estimativa do erro é se executar D sobre todos os objetos de $\mathbf{Z}_{ts}$ e encontrar a proporção de objetos classificados incorretamente a partir do número de erros (N_{erro})

$$\hat{P}_D = \frac{N_{\text{erro}}}{N_{ts}}$$

$\hat{P}_D$ também é chamada de taxa de erro aparente. A acurácia aparente pode ser obtida de $1 - \hat{P}_D$ (dualidade).

Seja $\hat{P}_D$ é uma estimativa da probabilidade P_D do classificador D cometer um erro. Se $N_{ts} > 30$, $\hat{P}_D \times N_{ts} > 5$ e $(1 - \hat{P}_D) \times N_{ts} > 5$, então com 95% de confiança o erro está no intervalo

$$\left[\hat{P}_D - 1,96 \sqrt{\frac{\hat{P}_D(1 - \hat{P}_D)}{N_{ts}}}, \hat{P}_D + 1,96 \sqrt{\frac{\hat{P}_D(1 - \hat{P}_D)}{N_{ts}}} \right]$$

Performance de Classificadores



Cálculo do Erro

Considere que um conjunto de dados rotulados $\mathbf{Z}_{ts}$ de tamanho $N_{ts} \times n$ está disponível obtenção da acurácia. Uma forma natural de se calcular uma estimativa do erro é se executar D sobre todos os objetos de $\mathbf{Z}_{ts}$ e encontrar a proporção de objetos classificados incorretamente a partir do número de erros (N_{erro})

$$\hat{P}_D = \frac{N_{\text{erro}}}{N_{ts}}$$

$\hat{P}_D$ também é chamada de taxa de erro aparente. A acurácia aparente pode ser obtida de $1 - \hat{P}_D$ (dualidade).

Seja $\hat{P}_D$ é uma estimativa da probabilidade P_D do classificador D cometer um erro. Se $N_{ts} > 30$, $\hat{P}_D \times N_{ts} > 5$ e $(1 - \hat{P}_D) \times N_{ts} > 5$, então com 95% de confiança o erro está no intervalo

$$\left[\hat{P}_D - 1,96 \sqrt{\frac{\hat{P}_D(1 - \hat{P}_D)}{N_{ts}}}, \hat{P}_D + 1,96 \sqrt{\frac{\hat{P}_D(1 - \hat{P}_D)}{N_{ts}}} \right]$$

Performance de Classificadores



Cálculo do Erro

Considere que um conjunto de dados rotulados $\mathbf{Z}_{ts}$ de tamanho $N_{ts} \times n$ está disponível obtenção da acurácia. Uma forma natural de se calcular uma estimativa do erro é se executar D sobre todos os objetos de $\mathbf{Z}_{ts}$ e encontrar a proporção de objetos classificados incorretamente a partir do número de erros (N_{erro})

$$\hat{P}_D = \frac{N_{\text{erro}}}{N_{ts}}$$

$\hat{P}_D$ também é chamada de taxa de erro aparente. A acurácia aparente pode ser obtida de $1 - \hat{P}_D$ (dualidade).

Seja $\hat{P}_D$ é uma estimativa da probabilidade P_D do classificador D cometer um erro. Se $N_{ts} > 30$, $\hat{P}_D \times N_{ts} > 5$ e $(1 - \hat{P}_D) \times N_{ts} > 5$, então com 95% de confiança o erro está no intervalo

$$\left[\hat{P}_D - 1,96 \sqrt{\frac{\hat{P}_D(1 - \hat{P}_D)}{N_{ts}}}, \hat{P}_D + 1,96 \sqrt{\frac{\hat{P}_D(1 - \hat{P}_D)}{N_{ts}}} \right]$$

Performance de Classificadores



Cálculo do Erro

Considere que um conjunto de dados rotulados $\mathbf{Z}_{ts}$ de tamanho $N_{ts} \times n$ está disponível obtenção da acurácia. Uma forma natural de se calcular uma estimativa do erro é se executar D sobre todos os objetos de $\mathbf{Z}_{ts}$ e encontrar a proporção de objetos classificados incorretamente a partir do número de erros (N_{erro})

$$\hat{P}_D = \frac{N_{\text{erro}}}{N_{ts}}$$

$\hat{P}_D$ também é chamada de taxa de erro aparente. A acurácia aparente pode ser obtida de $1 - \hat{P}_D$ (dualidade).

Seja $\hat{P}_D$ é uma estimativa da probabilidade P_D do classificador D cometer um erro. Se $N_{ts} > 30$, $\hat{P}_D \times N_{ts} > 5$ e $(1 - \hat{P}_D) \times N_{ts} > 5$, então com 95% de confiança o erro está no intervalo

$$\left[\hat{P}_D - 1,96 \sqrt{\frac{\hat{P}_D(1 - \hat{P}_D)}{N_{ts}}}, \hat{P}_D + 1,96 \sqrt{\frac{\hat{P}_D(1 - \hat{P}_D)}{N_{ts}}} \right]$$


Performance de Classificadores



Matriz de Confusão (ou Contingência)

Uma matriz de confusão exibe a distribuição de erros e acertos de um classificador D .

A entrada a_{ij} de tal matriz indica o número de elementos de $\mathbf{Z}_{ts}$ cuja verdadeira classe é ω_i mas que foram atribuídos pelo classificador D à classe ω_j .



		Predito	
		ω_1	ω_2
Correto	ω_1	7	0
	ω_2	1	7

A estimativa da acurácia do classificador pode ser calculada dividindo o traço da matriz pela soma total das entradas

$$\text{Acurácia} = \frac{7+7}{15} = 93,33\%$$


Performance de Classificadores



Matriz de Confusão (ou Contingência)

Uma matriz de confusão exibe a distribuição de erros e acertos de um classificador D .

A entrada a_{ij} de tal matriz indica o número de elementos de $\mathbf{Z}_{ts}$ cuja verdadeira classe é ω_i mas que foram atribuídos pelo classificador D à classe ω_j .



		Predito	
		ω_1	ω_2
Correto	ω_1	7	0
	ω_2	1	7

A estimativa da acurácia do classificador pode ser calculada dividindo o traço da matriz pela soma total das entradas

$$\text{Acurácia} = \frac{7 + 7}{15} = 93,33\%$$

Performance de Classificadores



Exemplo de Matriz de Confusão – UCI *Letters dataset*

Contém 20.000 imagens em preto e branco de letras maiúsculas em inglês descritas por meio de 16 características ($N = 20000$, $c = 26$, $n = 16$).

Exemplo de Matriz de Confusão – Linha para Letra 'H'


"H" labeled as:	A	B	C	D	E	F	G	H	I	J	K	L	M
Times:	1	6	1	18	0	1	2	159	0	0	30	0	1

"H" labeled as:	N	O	P	Q	R	S	T	U	V	W	X	Y	Z
Times:	27	33	2	9	21	0	0	11	4	3	20	1	0

Performance de Classificadores



Exemplo de Matriz de Confusão – Representação Gráfica



Performance de Classificadores



Matriz de Perdas

Erros em classificação nem sempre tem o mesmo custo. Uma matriz de perdas permite atribuir diferentes custos aos erros de um classificador D .

A entrada λ_{ij} de tal matriz indica a perda incorrida em atribuir a classe ω_i quando o rótulo correto do objeto for a classe ω_j .

Se um classificador estiver incerto sobre o rótulo de um objeto, ele poderia se recusar a tomar uma decisão, utilizando uma classe extra para indicar isso ("*refuse-to-decide*") cuja escolha deveria ser menos custosa que uma decisão incorreta.

Para um problema com c classes originais e uma opção de recusa, a matriz de perdas é de tamanho $(c + 1) \times c$.

Performance de Classificadores



Matriz de Perdas

Erros em classificação nem sempre tem o mesmo custo. Uma matriz de perdas permite atribuir diferentes custos aos erros de um classificador D .

A entrada λ_{ij} de tal matriz indica a perda incorrida em atribuir a classe ω_i quando o rótulo correto do objeto for a classe ω_j .

Se um classificador estiver incerto sobre o rótulo de um objeto, ele poderia se recusar a tomar uma decisão, utilizando uma classe extra para indicar isso ("*refuse-to-decide*") cuja escolha deveria ser menos custosa que uma decisão incorreta.

Para um problema com c classes originais e uma opção de recusa, a matriz de perdas é de tamanho $(c + 1) \times c$.

Performance de Classificadores



Matriz de Perdas

Erros em classificação nem sempre tem o mesmo custo. Uma matriz de perdas permite atribuir diferentes custos aos erros de um classificador D .

A entrada λ_{ij} de tal matriz indica a perda incorrida em atribuir a classe ω_i quando o rótulo correto do objeto for a classe ω_j .

Se um classificador estiver incerto sobre o rótulo de um objeto, ele poderia se recusar a tomar uma decisão, utilizando uma classe extra para indicar isso ("*refuse-to-decide*") cuja escolha deveria ser menos custosa que uma decisão incorreta.

Para um problema com c classes originais e uma opção de recusa, a matriz de perdas é de tamanho $(c + 1) \times c$.

Performance de Classificadores



Matriz de Perdas

Erros em classificação nem sempre tem o mesmo custo. Uma matriz de perdas permite atribuir diferentes custos aos erros de um classificador D .

A entrada λ_{ij} de tal matriz indica a perda incorrida em atribuir a classe ω_i quando o rótulo correto do objeto for a classe ω_j .

Se um classificador estiver incerto sobre o rótulo de um objeto, ele poderia se recusar a tomar uma decisão, utilizando uma classe extra para indicar isso ("*refuse-to-decide*") cuja escolha deveria ser menos custosa que uma decisão incorreta.

Para um problema com c classes originais e uma opção de recusa, a matriz de perdas é de tamanho $(c + 1) \times c$.

Protocolos de Treino/Teste



Uma estimativa de erro $\hat{P}_D$ só é válida apenas para um dado classificador e conjunto de teste para qual ela foi calculada.

É possível se treinar um classificador “melhor” a partir de diferentes dados de treino amostrados da distribuição associada ao problema.

Como então responder a questão: “Quão bem um dado modelo de classificação é capaz de resolver um problema?”

Suponha que esteja disponível um conjunto de dados Z de tamanho $N \times n$. Deseja-se utilizar a maior porção possível para se construir um classificador (treino) e também a maior porção possível (não usada anteriormente) para testar sua performance (teste).

Porém se usarmos todos os dados para treinar e os mesmos dados para o teste, podemos incorrer em “*overtraining*” – ele poderia aprender com perfeição sobre os dados disponíveis mas sua performance sobre dados desconhecidos não poderia ser predita.

Protocolos de Treino/Teste



Uma estimativa de erro $\hat{P}_D$ só é válida apenas para um dado classificador e conjunto de teste para qual ela foi calculada.

É possível se treinar um classificador “melhor” a partir de diferentes dados de treino amostrados da distribuição associada ao problema.

Como então responder a questão: “Quão bem um dado modelo de classificação é capaz de resolver um problema?”

Suponha que esteja disponível um conjunto de dados Z de tamanho $N \times n$. Deseja-se utilizar a maior porção possível para se construir um classificador (treino) e também a maior porção possível (não usada anteriormente) para testar sua performance (teste).

Porém se usarmos todos os dados para treinar e os mesmos dados para o teste, podemos incorrer em “*overtraining*” – ele poderia aprender com perfeição sobre os dados disponíveis mas sua performance sobre dados desconhecidos não poderia ser predita.

Protocolos de Treino/Teste



Uma estimativa de erro $\hat{P}_D$ só é válida apenas para um dado classificador e conjunto de teste para qual ela foi calculada.

É possível se treinar um classificador “melhor” a partir de diferentes dados de treino amostrados da distribuição associada ao problema.

Como então responder a questão: “Quão bem um dado modelo de classificação é capaz de resolver um problema?”

Suponha que esteja disponível um conjunto de dados Z de tamanho $N \times n$. Deseja-se utilizar a maior porção possível para se construir um classificador (treino) e também a maior porção possível (não usada anteriormente) para testar sua performance (teste).

Porém se usarmos todos os dados para treinar e os mesmos dados para o teste, podemos incorrer em “*overtraining*” – ele poderia aprender com perfeição sobre os dados disponíveis mas sua performance sobre dados desconhecidos não poderia ser predita.

Protocolos de Treino/Teste



Uma estimativa de erro $\hat{P}_D$ só é válida apenas para um dado classificador e conjunto de teste para qual ela foi calculada.

É possível se treinar um classificador “melhor” a partir de diferentes dados de treino amostrados da distribuição associada ao problema.

Como então responder a questão: “Quão bem um dado modelo de classificação é capaz de resolver um problema?”

Suponha que esteja disponível um conjunto de dados $\mathbf{Z}$ de tamanho $N \times n$. Deseja-se utilizar a maior porção possível para se construir um classificador (treino) e também a maior porção possível (não usada anteriormente) para testar sua performance (teste).

Porém se usarmos todos os dados para treinar e os mesmos dados para o teste, podemos incorrer em “*overtraining*” – ele poderia aprender com perfeição sobre os dados disponíveis mas sua performance sobre dados desconhecidos não poderia ser predita.

Protocolos de Treino/Teste



Uma estimativa de erro $\hat{P}_D$ só é válida apenas para um dado classificador e conjunto de teste para qual ela foi calculada.

É possível se treinar um classificador “melhor” a partir de diferentes dados de treino amostrados da distribuição associada ao problema.

Como então responder a questão: “Quão bem um dado modelo de classificação é capaz de resolver um problema?”

Suponha que esteja disponível um conjunto de dados $\mathbf{Z}$ de tamanho $N \times n$. Deseja-se utilizar a maior porção possível para se construir um classificador (treino) e também a maior porção possível (não usada anteriormente) para testar sua performance (teste).

Porém se usarmos todos os dados para treinar e os mesmos dados para o teste, podemos incorrer em “*overtraining*” – ele poderia aprender com perfeição sobre os dados disponíveis mas sua performance sobre dados desconhecidos não poderia ser predita.

Protocolos de Treino/Teste



Uma estimativa de erro $\hat{P}_D$ só é válida apenas para um dado classificador e conjunto de teste para qual ela foi calculada.

É possível se treinar um classificador “melhor” a partir de diferentes dados de treino amostrados da distribuição associada ao problema.

Como então responder a questão: “Quão bem um dado modelo de classificação é capaz de resolver um problema?”

Suponha que esteja disponível um conjunto de dados $\mathbf{Z}$ de tamanho $N \times n$. Deseja-se utilizar a maior porção possível para se construir um classificador (treino) e também a maior porção possível (não usada anteriormente) para testar sua performance (teste).

Porém se usarmos todos os dados para treinar e os mesmos dados para o teste, podemos incorrer em “*overtraing*” – ele poderia aprender com perfeição sobre os dados disponíveis mas sua performance sobre dados desconhecidos não poderia ser predita.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre Z e testa-se o mesmo usando Z .

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se Z em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.
Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de Z em partes para treino e teste.
Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.
As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre Z e testa-se o mesmo usando Z .

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se Z em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.
Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de Z em partes para treino e teste.
Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.
As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre $\mathbf{Z}$ e testa-se o mesmo usando $\mathbf{Z}$.

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se $\mathbf{Z}$ em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.
Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de $\mathbf{Z}$ em partes para treino e teste.
Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.
As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre $\mathbf{Z}$ e testa-se o mesmo usando $\mathbf{Z}$.

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se $\mathbf{Z}$ em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.
Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de $\mathbf{Z}$ em partes para treino e teste.
Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.
As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre $\mathbf{Z}$ e testa-se o mesmo usando $\mathbf{Z}$.

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se $\mathbf{Z}$ em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.

Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de $\mathbf{Z}$ em partes para treino e teste.

Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.

As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre $\mathbf{Z}$ e testa-se o mesmo usando $\mathbf{Z}$.

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se $\mathbf{Z}$ em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.
Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de $\mathbf{Z}$ em partes para treino e teste.
Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.
As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre $\mathbf{Z}$ e testa-se o mesmo usando $\mathbf{Z}$.

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se $\mathbf{Z}$ em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.
Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de $\mathbf{Z}$ em partes para treino e teste.

Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.

As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre $\mathbf{Z}$ e testa-se o mesmo usando $\mathbf{Z}$.

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se $\mathbf{Z}$ em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.
Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de $\mathbf{Z}$ em partes para treino e teste.
Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.
As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Daí, a importância de se ter conjuntos separados para treino e para teste.

Os protocolos mais amplamente utilizados pode ser resumidos a seguir:

Resubstitution Projeta-se um classificador D sobre $\mathbf{Z}$ e testa-se o mesmo usando $\mathbf{Z}$.

$\hat{P}_D$ é provavelmente muito otimista.

Hold-out Tradicionalmente, divide-se $\mathbf{Z}$ em duas metades; usando uma para treinar e a outra para teste e cálculo de $\hat{P}_D$.
Divisões em outras proporções também são usadas.

Repeated hold-out Esta é uma versão do método anterior, em que são feitas L divisões randômicas de $\mathbf{Z}$ em partes para treino e teste.
Ao final, a média de todas as estimativas de $\hat{P}_D$ é obtida.
As proporções usuais são 90% para treino e 10% para teste.

Protocolos de Treino/Teste



Cross-validation Escolhe-se um inteiro K (preferencialmente um fator de N) e divide-se randomicamente $\mathbf{Z}$ em K subconjuntos de tamanho N/K .

A seguir, usa-se um subconjunto para testar o classificador treinado com a união dos demais $K - 1$ subconjuntos.

Esse procedimento é repetido K vezes escolhendo-se um subconjunto diferente para teste a cada repetição.

Para se obter a estimativa final do valor de $\hat{P}_D$ utiliza-se a média das K estimativas.

Protocolos de Treino/Teste



Cross-validation Escolhe-se um inteiro K (preferencialmente um fator de N) e divide-se randomicamente $\mathbf{Z}$ em K subconjuntos de tamanho N/K .

A seguir, usa-se um subconjunto para testar o classificador treinado com a união dos demais $K - 1$ subconjuntos.

Esse procedimento é repetido K vezes escolhendo-se um subconjunto diferente para teste a cada repetição.

Para se obter a estimativa final do valor de $\hat{P}_D$ utiliza-se a média das K estimativas.

Protocolos de Treino/Teste



Cross-validation Escolhe-se um inteiro K (preferencialmente um fator de N) e divide-se randomicamente $\mathbf{Z}$ em K subconjuntos de tamanho N/K .

A seguir, usa-se um subconjunto para testar o classificador treinado com a união dos demais $K - 1$ subconjuntos.

Esse procedimento é repetido K vezes escolhendo-se um subconjunto diferente para teste a cada repetição.

Para se obter a estimativa final do valor de $\hat{P}_D$ utiliza-se a média das K estimativas.

Protocolos de Treino/Teste



Cross-validation Escolhe-se um inteiro K (preferencialmente um fator de N) e divide-se randomicamente $\mathbf{Z}$ em K subconjuntos de tamanho N/K .

A seguir, usa-se um subconjunto para testar o classificador treinado com a união dos demais $K - 1$ subconjuntos.

Esse procedimento é repetido K vezes escolhendo-se um subconjunto diferente para teste a cada repetição.

Para se obter a estimativa final do valor de $\hat{P}_D$ utiliza-se a média das K estimativas.

Protocolos de Treino/Teste



Repeated cross-validation Para se reduzir o efeito oriundo de uma única divisão de Z em K subconjuntos, pode-se repetir o método de *cross-validation*.

Em um $M \times K$ -fold *cross-validation*, os dados são divididos M vezes em K subconjuntos, e o método de *cross-validation* é executado para cada divisão.

Este processo resulta em $M \times K$ estimativas para $\hat{P}_D$ cuja média é usada para se obter o resultado final.

Uma escolha típica para esse protocolo é um 10×10 -fold *cross-validation*.

Protocolos de Treino/Teste



Repeated cross-validation Para se reduzir o efeito oriundo de uma única divisão de Z em K subconjuntos, pode-se repetir o método de *cross-validation*.

Em um $M \times K$ -fold *cross-validation*, os dados são divididos M vezes em K subconjuntos, e o método de *cross-validation* é executado para cada divisão.

Este processo resulta em $M \times K$ estimativas para $\hat{P}_D$ cuja média é usada para se obter o resultado final.

Uma escolha típica para esse protocolo é um 10×10 -fold *cross-validation*.

Protocolos de Treino/Teste



Repeated cross-validation Para se reduzir o efeito oriundo de uma única divisão de $\mathbf{Z}$ em K subconjuntos, pode-se repetir o método de *cross-validation*.

Em um $M \times K$ -fold *cross-validation*, os dados são divididos M vezes em K subconjuntos, e o método de *cross-validation* é executado para cada divisão.

Este processo resulta em $M \times K$ estimativas para $\hat{P}_D$ cuja média é usada para se obter o resultado final.

Uma escolha típica para esse protocolo é um 10×10 -fold *cross-validation*.

Protocolos de Treino/Teste



Repeated cross-validation Para se reduzir o efeito oriundo de uma única divisão de $\mathbf{Z}$ em K subconjuntos, pode-se repetir o método de *cross-validation*.

Em um $M \times K$ -fold *cross-validation*, os dados são divididos M vezes em K subconjuntos, e o método de *cross-validation* é executado para cada divisão.

Este processo resulta em $M \times K$ estimativas para $\hat{P}_D$ cuja média é usada para se obter o resultado final.

Uma escolha típica para esse protocolo é um 10×10 -fold *cross-validation*.

Protocolos de Treino/Teste



Leave-one-out Este protocolo é equivalente ao *cross-validation* em que $K = N$, isto é, cada objeto é separado dos demais.

Um classificador é treinado com os $N - 1$ objetos e testado com o objeto separado.

$\hat{P}_D$ representa a proporção dos N objetos incorretamente classificados.

Bootstrap É feita uma amostragem aleatória com reposição de L subconjuntos de cardinalidade N a partir do conjunto original de dados $\mathbf{Z}$.

Aproximadamente 37% ($1/e$) dos dados são selecionados – porção chamada de “*out-of-bag*”.

O classificador é construído com base na amostragem feita e testado com os dados “*out-of-bag*”. Ao final, a média de L estimativas de $\hat{P}_D$ é obtida.

Pode-se combinar as taxas de erro dos métodos *resubstitution* e *bootstrap* com diferentes pesos.

Protocolos de Treino/Teste



Leave-one-out Este protocolo é equivalente ao *cross-validation* em que $K = N$, isto é, cada objeto é separado dos demais. Um classificador é treinado com os $N - 1$ objetos e testado com o objeto separado.

$\hat{P}_D$ representa a proporção dos N objetos incorretamente classificados.

Bootstrap É feita uma amostragem aleatória com reposição de L subconjuntos de cardinalidade N a partir do conjunto original de dados $\mathbf{Z}$.

Aproximadamente 37% ($1/e$) dos dados são selecionados – porção chamada de “*out-of-bag*”.

O classificador é construído com base na amostragem feita e testado com os dados “*out-of-bag*”. Ao final, a média de L estimativas de $\hat{P}_D$ é obtida.

Pode-se combinar as taxas de erro dos métodos *resubstitution* e *bootstrap* com diferentes pesos.

Protocolos de Treino/Teste



Leave-one-out Este protocolo é equivalente ao *cross-validation* em que $K = N$, isto é, cada objeto é separado dos demais. Um classificador é treinado com os $N - 1$ objetos e testado com o objeto separado. $\hat{P}_D$ representa a proporção dos N objetos incorretamente classificados.

Bootstrap É feita uma amostragem aleatória com reposição de L subconjuntos de cardinalidade N a partir do conjunto original de dados $\mathbf{Z}$. Aproximadamente 37% ($1/e$) dos dados são selecionados – porção chamada de “*out-of-bag*”. O classificador é construído com base na amostragem feita e testado com os dados “*out-of-bag*”. Ao final, a média de L estimativas de $\hat{P}_D$ é obtida. Pode-se combinar as taxas de erro dos métodos *resubstitution* e *bootstrap* com diferentes pesos.

Protocolos de Treino/Teste



Leave-one-out Este protocolo é equivalente ao *cross-validation* em que $K = N$, isto é, cada objeto é separado dos demais. Um classificador é treinado com os $N - 1$ objetos e testado com o objeto separado. $\hat{P}_D$ representa a proporção dos N objetos incorretamente classificados.

Bootstrap É feita uma amostragem aleatória com reposição de L subconjuntos de cardinalidade N a partir do conjunto original de dados $\mathbf{Z}$.

Aproximadamente 37% ($1/e$) dos dados são selecionados – porção chamada de “*out-of-bag*”. O classificador é construído com base na amostragem feita e testado com os dados “*out-of-bag*”. Ao final, a média de L estimativas de $\hat{P}_D$ é obtida. Pode-se combinar as taxas de erro dos métodos *resubstitution* e *bootstrap* com diferentes pesos.

Protocolos de Treino/Teste



Leave-one-out Este protocolo é equivalente ao *cross-validation* em que $K = N$, isto é, cada objeto é separado dos demais. Um classificador é treinado com os $N - 1$ objetos e testado com o objeto separado. $\hat{P}_D$ representa a proporção dos N objetos incorretamente classificados.

Bootstrap É feita uma amostragem aleatória com reposição de L subconjuntos de cardinalidade N a partir do conjunto original de dados $\mathbf{Z}$. Aproximadamente 37% ($1/e$) dos dados são selecionados – porção chamada de “*out-of-bag*”. O classificador é construído com base na amostragem feita e testado com os dados “*out-of-bag*”. Ao final, a média de L estimativas de $\hat{P}_D$ é obtida. Pode-se combinar as taxas de erro dos métodos *resubstitution* e *bootstrap* com diferentes pesos.

Protocolos de Treino/Teste



Leave-one-out Este protocolo é equivalente ao *cross-validation* em que $K = N$, isto é, cada objeto é separado dos demais. Um classificador é treinado com os $N - 1$ objetos e testado com o objeto separado. $\hat{P}_D$ representa a proporção dos N objetos incorretamente classificados.

Bootstrap É feita uma amostragem aleatória com reposição de L subconjuntos de cardinalidade N a partir do conjunto original de dados $\mathbf{Z}$. Aproximadamente 37% ($1/e$) dos dados são selecionados – porção chamada de “*out-of-bag*”. O classificador é construído com base na amostragem feita e testado com os dados “*out-of-bag*”. Ao final, a média de L estimativas de $\hat{P}_D$ é obtida.

Pode-se combinar as taxas de erro dos métodos *resubstitution* e *bootstrap* com diferentes pesos.

Protocolos de Treino/Teste



Leave-one-out Este protocolo é equivalente ao *cross-validation* em que $K = N$, isto é, cada objeto é separado dos demais. Um classificador é treinado com os $N - 1$ objetos e testado com o objeto separado. $\hat{P}_D$ representa a proporção dos N objetos incorretamente classificados.

Bootstrap É feita uma amostragem aleatória com reposição de L subconjuntos de cardinalidade N a partir do conjunto original de dados $\mathbf{Z}$. Aproximadamente 37% ($1/e$) dos dados são selecionados – porção chamada de “*out-of-bag*”. O classificador é construído com base na amostragem feita e testado com os dados “*out-of-bag*”. Ao final, a média de L estimativas de $\hat{P}_D$ é obtida. Pode-se combinar as taxas de erro dos métodos *resubstitution* e *bootstrap* com diferentes pesos.

Overtraining / Peeking



Teste deve ser realizado sobre dados não utilizados anteriormente.

Portanto, todos os parâmetros devem ser ajustados sobre os dados de treinamento.

Um erro comum em experimentos de classificação é selecionar um conjunto de características usando um conjunto de dados e, em seguida, executar experimentos com um dos protocolos anteriores para se avaliar a acurácia sobre aquele conjunto de dados.

Chama-se esse problema de "*peeking*" ("espiada furtiva" / "olhadinha") – utilizando os mesmos dados é provável produzir uma tendência otimista na avaliação de erro.

Overtraining / Peeking



Teste deve ser realizado sobre dados não utilizados anteriormente.

Portanto, todos os parâmetros devem ser ajustados sobre os dados de treinamento.

Um erro comum em experimentos de classificação é selecionar um conjunto de características usando um conjunto de dados e, em seguida, executar experimentos com um dos protocolos anteriores para se avaliar a acurácia sobre aquele conjunto de dados.

Chama-se esse problema de “*peeking*” (“espiada furtiva” / “olhadinha”) – utilizando os mesmos dados é provável produzir uma tendência otimista na avaliação de erro.

Overtraining / Peeking



Teste deve ser realizado sobre dados não utilizados anteriormente.

Portanto, todos os parâmetros devem ser ajustados sobre os dados de treinamento.

Um erro comum em experimentos de classificação é selecionar um conjunto de características usando um conjunto de dados e, em seguida, executar experimentos com um dos protocolos anteriores para se avaliar a acurácia sobre aquele conjunto de dados.

Chama-se esse problema de "*peeking*" ("espiada furtiva" / "olhadinha") – utilizando os mesmos dados é provável produzir uma tendência otimista na avaliação de erro.

Overtraining / Peeking



Teste deve ser realizado sobre dados não utilizados anteriormente.

Portanto, todos os parâmetros devem ser ajustados sobre os dados de treinamento.


Um erro comum em experimentos de classificação é selecionar um conjunto de características usando um conjunto de dados e, em seguida, executar experimentos com um dos protocolos anteriores para se avaliar a acurácia sobre aquele conjunto de dados.

Chama-se esse problema de “*peeking*” (“espiada furtiva” / “olhadinha”) – utilizando os mesmos dados é provável produzir uma tendência otimista na avaliação de erro.

Overtraining / Peeking



Overtraining – UCI Letters dataset




Um problema comum é declarar que o classificador apresentou um erro de 21,37% (mínimo encontrado ao longo dos testes) – mas deve-se considerar que o conjunto de teste foi utilizado para se encontrar o melhor valor do parâmetro.

Overtraining / Peeking



Overtraing – UCI Letters dataset



Um problema comum é declarar que o classificador apresentou um erro de 21,37% (mínimo encontrado ao longo dos testes) – mas deve-se considerar que o conjunto de teste foi utilizado para se encontrar o melhor valor do parâmetro.

Comparação Experimental



Não existe um único classificador “ideal”.

Classificadores aplicados a problemas diferentes e treinados por diferentes algoritmos apresentam performances diferentes.

Segundo Duin (1996), o desempenho de um classificador depende da experiência e da vontade do seu desenvolvedor.

Não há muito o que se fazer para classificadores com estruturas pre-determinadas e procedimentos de treinamento fixos (Duin os chama de classificadores “automáticos”).

Contudo, para classificadores com muitos parâmetros de treinamento, pode-se conseguir fazê-los funcionar bem ou não.

Comparação Experimental



Não existe um único classificador “ideal”.

Classificadores aplicados a problemas diferentes e treinados por diferentes algoritmos apresentam performances diferentes.

Segundo Duin (1996), o desempenho de um classificador depende da experiência e da vontade do seu desenvolvedor.

Não há muito o que se fazer para classificadores com estruturas pre-determinadas e procedimentos de treinamento fixos (Duin os chama de classificadores “automáticos”).

Contudo, para classificadores com muitos parâmetros de treinamento, pode-se conseguir fazê-los funcionar bem ou não.

Comparação Experimental



Não existe um único classificador “ideal”.

Classificadores aplicados a problemas diferentes e treinados por diferentes algoritmos apresentam performances diferentes.

Segundo Duin (1996), o desempenho de um classificador depende da experiência e da vontade do seu desenvolvedor.

Não há muito o que se fazer para classificadores com estruturas pre-determinadas e procedimentos de treinamento fixos (Duin os chama de classificadores “automáticos”).

Contudo, para classificadores com muitos parâmetros de treinamento, pode-se conseguir fazê-los funcionar bem ou não.

Comparação Experimental



Não existe um único classificador “ideal”.

Classificadores aplicados a problemas diferentes e treinados por diferentes algoritmos apresentam performances diferentes.

Segundo Duin (1996), o desempenho de um classificador depende da experiência e da vontade do seu desenvolvedor.

Não há muito o que se fazer para classificadores com estruturas pre-determinadas e procedimentos de treinamento fixos (Duin os chama de classificadores “automáticos”).

Contudo, para classificadores com muitos parâmetros de treinamento, pode-se conseguir fazê-los funcionar bem ou não.

Comparação Experimental



Não existe um único classificador “ideal”.

Classificadores aplicados a problemas diferentes e treinados por diferentes algoritmos apresentam performances diferentes.

Segundo Duin (1996), o desempenho de um classificador depende da experiência e da vontade do seu desenvolvedor.

Não há muito o que se fazer para classificadores com estruturas pre-determinadas e procedimentos de treinamento fixos (Duin os chama de classificadores “automáticos”).

Contudo, para classificadores com muitos parâmetros de treinamento, pode-se conseguir fazê-los funcionar bem ou não.

Comparação Experimental



Alguns “bons” princípios:

- Seleccionar os procedimentos de treino antecipadamente e mantê-los inalterados durante o treinamento. Quando da publicação, fornecer detalhes suficientes para permitir que os experimentos sejam replicados
- Comparar versões modificadas do classificador com aquele originalmente utilizado para depois comparar com outros modelos. Caso contrário, se uma pequena modificação do classificador for comparada com um outro classificador completamente diferente, não fica claro quem deve receber o crédito (o modelo original ou aquele modificado)
- Certificar-se de que toda informação sobre os dados é utilizada de forma igualitária por todos (inicialização heurística × randômica)
- Certificar-se de que o conjunto de teste não foi utilizado em nenhuma etapa do treinamento
- Quando possível, fornecer dados sobre a complexidade do classificador: tempos de treinamento e teste, requisitos de memória, entre outros

Comparação Experimental



Alguns “bons” princípios:

- Selecionar os procedimentos de treino antecipadamente e mantê-los inalterados durante o treinamento. Quando da publicação, fornecer detalhes suficientes para permitir que os experimentos sejam replicados
- Comparar versões modificadas do classificador com aquele originalmente utilizado para depois comparar com outros modelos. Caso contrário, se uma pequena modificação do classificador for comparada com um outro classificador completamente diferente, não fica claro quem deve receber o crédito (o modelo original ou aquele modificado)
- Certificar-se de que toda informação sobre os dados é utilizada de forma igualitária por todos (inicialização heurística × randômica)
- Certificar-se de que o conjunto de teste não foi utilizado em nenhuma etapa do treinamento
- Quando possível, fornecer dados sobre a complexidade do classificador: tempos de treinamento e teste, requisitos de memória, entre outros

Comparação Experimental



Alguns “bons” princípios:

- Selecionar os procedimentos de treino antecipadamente e mantê-los inalterados durante o treinamento. Quando da publicação, fornecer detalhes suficientes para permitir que os experimentos sejam replicados
- Comparar versões modificadas do classificador com aquele originalmente utilizado para depois comparar com outros modelos. Caso contrário, se uma pequena modificação do classificador for comparada com um outro classificador completamente diferente, não fica claro quem deve receber o crédito (o modelo original ou aquele modificado)
- Certificar-se de que toda informação sobre os dados é utilizada de forma igualitária por todos (inicialização heurística × randômica)
- Certificar-se de que o conjunto de teste não foi utilizado em nenhuma etapa do treinamento
- Quando possível, fornecer dados sobre a complexidade do classificador: tempos de treinamento e teste, requisitos de memória, entre outros

Comparação Experimental



Alguns “bons” princípios:

- Selecionar os procedimentos de treino antecipadamente e mantê-los inalterados durante o treinamento. Quando da publicação, fornecer detalhes suficientes para permitir que os experimentos sejam replicados
- Comparar versões modificadas do classificador com aquele originalmente utilizado para depois comparar com outros modelos. Caso contrário, se uma pequena modificação do classificador for comparada com um outro classificador completamente diferente, não fica claro quem deve receber o crédito (o modelo original ou aquele modificado)
- Certificar-se de que toda informação sobre os dados é utilizada de forma igualitária por todos (inicialização heurística × randômica)
- Certificar-se de que o conjunto de teste não foi utilizado em nenhuma etapa do treinamento
- Quando possível, fornecer dados sobre a complexidade do classificador: tempos de treinamento e teste, requisitos de memória, entre outros

Comparação Experimental



Alguns “bons” princípios:

- Selecionar os procedimentos de treino antecipadamente e mantê-los inalterados durante o treinamento. Quando da publicação, fornecer detalhes suficientes para permitir que os experimentos sejam replicados
- Comparar versões modificadas do classificador com aquele originalmente utilizado para depois comparar com outros modelos. Caso contrário, se uma pequena modificação do classificador for comparada com um outro classificador completamente diferente, não fica claro quem deve receber o crédito (o modelo original ou aquele modificado)
- Certificar-se de que toda informação sobre os dados é utilizada de forma igualitária por todos (inicialização heurística × randômica)
- Certificar-se de que o conjunto de teste não foi utilizado em nenhuma etapa do treinamento
- Quando possível, fornecer dados sobre a complexidade do classificador: tempos de treinamento e teste, requisitos de memória, entre outros

Abordagem Bayesiana



Embora existam vários tipos de incerteza, um modelo probabilístico se ajusta surpreendentemente bem a maioria dos problemas.

Suponha que o rótulo de uma classe ω seja uma variável aleatória que assume valores em um conjunto $\Omega = \{\omega_1, \omega_2, \dots, \omega_c\}$.

As probabilidades *a priori* $P(\omega_i), i = 1, \dots, c$ representam a *função de probabilidade* da variável ω , em que:

$$0 \leq P(\omega_i) \leq 1 \quad \text{e} \quad \sum_{i=1}^c P(\omega_i) = 1$$

Pode-se construir um classificador baseado apenas nessas informações, em que será sempre usado o rótulo da classe de maior probabilidade *a priori* para se minimizar o erro de classificação.

Abordagem Bayesiana



Embora existam vários tipos de incerteza, um modelo probabilístico se ajusta surpreendentemente bem a maioria dos problemas.

Suponha que o rótulo de uma classe ω seja uma variável aleatória que assume valores em um conjunto $\Omega = \{\omega_1, \omega_2, \dots, \omega_c\}$.

As probabilidades *a priori* $P(\omega_i), i = 1, \dots, c$ representam a *função de probabilidade* da variável ω , em que:

$$0 \leq P(\omega_i) \leq 1 \quad \text{e} \quad \sum_{i=1}^c P(\omega_i) = 1$$

Pode-se construir um classificador baseado apenas nessas informações, em que será sempre usado o rótulo da classe de maior probabilidade *a priori* para se minimizar o erro de classificação.

Abordagem Bayesiana



Embora existam vários tipos de incerteza, um modelo probabilístico se ajusta surpreendentemente bem a maioria dos problemas.

Suponha que o rótulo de uma classe ω seja uma variável aleatória que assume valores em um conjunto $\Omega = \{\omega_1, \omega_2, \dots, \omega_c\}$.

As probabilidades *a priori* $P(\omega_i), i = 1, \dots, c$ representam a *função de probabilidade* da variável ω , em que:

$$0 \leq P(\omega_i) \leq 1 \quad \text{e} \quad \sum_{i=1}^c P(\omega_i) = 1$$

Pode-se construir um classificador baseado apenas nessas informações, em que será sempre usado o rótulo da classe de maior probabilidade *a priori* para se minimizar o erro de classificação.

Abordagem Bayesiana



Embora existam vários tipos de incerteza, um modelo probabilístico se ajusta surpreendentemente bem a maioria dos problemas.

Suponha que o rótulo de uma classe ω seja uma variável aleatória que assume valores em um conjunto $\Omega = \{\omega_1, \omega_2, \dots, \omega_c\}$.

As probabilidades *a priori* $P(\omega_i), i = 1, \dots, c$ representam a *função de probabilidade* da variável ω , em que:

$$0 \leq P(\omega_i) \leq 1 \quad \text{e} \quad \sum_{i=1}^c P(\omega_i) = 1$$

Pode-se construir um classificador baseado apenas nessas informações, em que será sempre usado o rótulo da classe de maior probabilidade *a priori* para se minimizar o erro de classificação.

Abordagem Bayesiana



Entretanto, por meio da mensuração de características relevantes dos objetos organizadas em um vetor $\mathbf{x} \in \mathbb{R}^n$, deve-se ser capaz de tomar decisões mais precisas sobre um objeto em particular.

Suponha que os objetos da classe ω_i são distribuídos em $\mathbb{R}^n$ de acordo com a *função de densidade de probabilidade* condicional $p(\mathbf{x}|\omega_i)$ em que $p(\mathbf{x}|\omega_i) \geq 0, \forall \mathbf{x} \in \mathbb{R}^n$ e

$$\int_{\mathbb{R}^n} p(\mathbf{x}|\omega_i) d\mathbf{x} = 1, \quad i = 1, \dots, c.$$

A probabilidade (marginal ou evidência) de $\mathbf{x} \in \mathbb{R}^n$ é dada por:

$$p(\mathbf{x}) = \sum_{i=1}^c P(\omega_i) p(\mathbf{x}|\omega_i).$$

Abordagem Bayesiana



Entretanto, por meio da mensuração de características relevantes dos objetos organizadas em um vetor $\mathbf{x} \in \mathbb{R}^n$, deve-se ser capaz de tomar decisões mais precisas sobre um objeto em particular.

Suponha que os objetos da classe ω_i são distribuídos em $\mathbb{R}^n$ de acordo com a *função de densidade de probabilidade* condicional $p(\mathbf{x}|\omega_i)$ em que $p(\mathbf{x}|\omega_i) \geq 0, \forall \mathbf{x} \in \mathbb{R}^n$ e

$$\int_{\mathbb{R}^n} p(\mathbf{x}|\omega_i) d\mathbf{x} = 1, \quad i = 1, \dots, c.$$

A probabilidade (marginal ou evidência) de $\mathbf{x} \in \mathbb{R}^n$ é dada por:

$$p(\mathbf{x}) = \sum_{i=1}^c P(\omega_i) p(\mathbf{x}|\omega_i).$$

Abordagem Bayesiana



Entretanto, por meio da mensuração de características relevantes dos objetos organizadas em um vetor $\mathbf{x} \in \mathbb{R}^n$, deve-se ser capaz de tomar decisões mais precisas sobre um objeto em particular.

Suponha que os objetos da classe ω_i são distribuídos em $\mathbb{R}^n$ de acordo com a *função de densidade de probabilidade* condicional $p(\mathbf{x}|\omega_i)$ em que $p(\mathbf{x}|\omega_i) \geq 0, \forall \mathbf{x} \in \mathbb{R}^n$ e

$$\int_{\mathbb{R}^n} p(\mathbf{x}|\omega_i) d\mathbf{x} = 1, \quad i = 1, \dots, c.$$

A probabilidade (marginal ou evidência) de $\mathbf{x} \in \mathbb{R}^n$ é dada por:

$$p(\mathbf{x}) = \sum_{i=1}^c P(\omega_i) p(\mathbf{x}|\omega_i).$$

Abordagem Bayesiana



Dadas as probabilidades *a priori* e as *fçs de densidade de probabilidade* condicionais, pode-se obter a probabilidade *a posteriori* de que o rótulo de classe de um dado $\mathbf{x}$ seja ω_i da seguinte forma:

$$P(\omega_i|\mathbf{x}) = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{p(\mathbf{x})} = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{\sum_{i=1}^c P(\omega_i) p(\mathbf{x}|\omega_i)}$$

A decisão de classificação deve ser tomada com base na probabilidade *a posteriori*, escolhendo-se a classe de maior valor de probabilidade *a posteriori* (pois leva ao menor erro possível).

Também é válido para caso discreto em que $\mathbf{x} \in \mathbf{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\}$. Basta usar as *funções de probabilidade* condicionais $P(\mathbf{x}|\omega_i)$ em que:

$$0 \leq P(\mathbf{x}|\omega_i) \leq 1, \forall \mathbf{x} \in \mathbf{V} \quad \text{e} \quad \sum_{j=1}^s P(\mathbf{v}_j|\omega_i) = 1$$

Abordagem Bayesiana



Dadas as probabilidades *a priori* e as *fçs de densidade de probabilidade* condicionais, pode-se obter a probabilidade *a posteriori* de que o rótulo de classe de um dado $\mathbf{x}$ seja ω_i da seguinte forma:

$$P(\omega_i|\mathbf{x}) = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{p(\mathbf{x})} = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{\sum_{i=1}^c P(\omega_i) p(\mathbf{x}|\omega_i)}$$

A decisão de classificação deve ser tomada com base na probabilidade *a posteriori*, escolhendo-se a classe de maior valor de probabilidade *a posteriori* (pois leva ao menor erro possível).

Também é válido para caso discreto em que $\mathbf{x} \in \mathbf{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\}$. Basta usar as *funções de probabilidade* condicionais $P(\mathbf{x}|\omega_i)$ em que:

$$0 \leq P(\mathbf{x}|\omega_i) \leq 1, \forall \mathbf{x} \in \mathbf{V} \quad \text{e} \quad \sum_{j=1}^s P(\mathbf{v}_j|\omega_i) = 1$$

Abordagem Bayesiana



Dadas as probabilidades *a priori* e as *fçs de densidade de probabilidade* condicionais, pode-se obter a probabilidade *a posteriori* de que o rótulo de classe de um dado $\mathbf{x}$ seja ω_i da seguinte forma:

$$P(\omega_i|\mathbf{x}) = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{p(\mathbf{x})} = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{\sum_{i=1}^c P(\omega_i) p(\mathbf{x}|\omega_i)}$$

A decisão de classificação deve ser tomada com base na probabilidade *a posteriori*, escolhendo-se a classe de maior valor de probabilidade *a posteriori* (pois leva ao menor erro possível).

Também é válido para caso discreto em que $\mathbf{x} \in \mathbf{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\}$. Basta usar as *funções de probabilidade* condicionais $P(\mathbf{x}|\omega_i)$ em que:

$$0 \leq P(\mathbf{x}|\omega_i) \leq 1, \forall \mathbf{x} \in \mathbf{V} \quad \text{e} \quad \sum_{j=1}^s P(\mathbf{v}_j|\omega_i) = 1$$

Abordagem Bayesiana



Dadas as probabilidades *a priori* e as *fçs de densidade de probabilidade* condicionais, pode-se obter a probabilidade *a posteriori* de que o rótulo de classe de um dado $\mathbf{x}$ seja ω_i da seguinte forma:

$$P(\omega_i|\mathbf{x}) = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{p(\mathbf{x})} = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{\sum_{i=1}^c P(\omega_i) p(\mathbf{x}|\omega_i)}$$

A decisão de classificação deve ser tomada com base na probabilidade *a posteriori*, escolhendo-se a classe de maior valor de probabilidade *a posteriori* (pois leva ao menor erro possível).

Também é válido para caso discreto em que $\mathbf{x} \in \mathbf{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\}$. Basta usar as *funções de probabilidade* condicionais $P(\mathbf{x}|\omega_i)$ em que:

$$0 \leq P(\mathbf{x}|\omega_i) \leq 1, \forall \mathbf{x} \in \mathbf{V} \quad \text{e} \quad \sum_{j=1}^s P(\mathbf{v}_j|\omega_i) = 1$$

Abordagem Bayesiana



Dadas as probabilidades *a priori* e as *fçs de densidade de probabilidade* condicionais, pode-se obter a probabilidade *a posteriori* de que o rótulo de classe de um dado $\mathbf{x}$ seja ω_i da seguinte forma:

$$P(\omega_i|\mathbf{x}) = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{p(\mathbf{x})} = \frac{P(\omega_i) p(\mathbf{x}|\omega_i)}{\sum_{i=1}^c P(\omega_i) p(\mathbf{x}|\omega_i)}$$

A decisão de classificação deve ser tomada com base na probabilidade *a posteriori*, escolhendo-se a classe de maior valor de probabilidade *a posteriori* (pois leva ao menor erro possível).

Também é válido para caso discreto em que $\mathbf{x} \in \mathbf{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\}$. Basta usar as *funções de probabilidade* condicionais $P(\mathbf{x}|\omega_i)$ em que:

$$0 \leq P(\mathbf{x}|\omega_i) \leq 1, \forall \mathbf{x} \in \mathbf{V} \quad \text{e} \quad \sum_{j=1}^s P(\mathbf{v}_j|\omega_i) = 1$$

Abordagem Bayesiana



Exemplo

Suponha uma máquina que falha devido a problemas no motor ou na transmissão. A localização do problema só pode ser determinada com certeza depois de desmontada a máquina.

Contudo, a falha apresenta 03 sintomas observáveis: aquecimento (AQ), tração irregular (TI) ou ambos (AT). Registros anteriores permitiram o levantamento das seguintes probabilidades condicionais – $p(x_j|\omega_i)$:

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,1	0,4	0,5
Transmissão (ω_2)	0,5	0,3	0,2

Além disso, sabe-se que 60% das falhas são devido a problemas na transmissão. Então $p(\omega_2) = 0,6$ (e, obviamente, $p(\omega_1) = 0,4$).

Abordagem Bayesiana



Exemplo

Suponha uma máquina que falha devido a problemas no motor ou na transmissão. A localização do problema só pode ser determinada com certeza depois de desmontada a máquina.

Contudo, a falha apresenta 03 sintomas observáveis: aquecimento (AQ), tração irregular (TI) ou ambos (AT). Registros anteriores permitiram o levantamento das seguintes probabilidades condicionais – $p(x_j|\omega_i)$:

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,1	0,4	0,5
Transmissão (ω_2)	0,5	0,3	0,2

Além disso, sabe-se que 60% das falhas são devido a problemas na transmissão. Então $p(\omega_2) = 0,6$ (e, obviamente, $p(\omega_1) = 0,4$).

Abordagem Bayesiana



Exemplo

Suponha uma máquina que falha devido a problemas no motor ou na transmissão. A localização do problema só pode ser determinada com certeza depois de desmontada a máquina.

Contudo, a falha apresenta 03 sintomas observáveis: aquecimento (AQ), tração irregular (TI) ou ambos (AT). Registros anteriores permitiram o levantamento das seguintes probabilidades condicionais – $p(x_j|\omega_i)$:

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,1	0,4	0,5
Transmissão (ω_2)	0,5	0,3	0,2

Além disso, sabe-se que 60% das falhas são devido a problemas na transmissão. Então $p(\omega_2) = 0,6$ (e, obviamente, $p(\omega_1) = 0,4$).

Abordagem Bayesiana



Exemplo

Suponha uma máquina que falha devido a problemas no motor ou na transmissão. A localização do problema só pode ser determinada com certeza depois de desmontada a máquina.

Contudo, a falha apresenta 03 sintomas observáveis: aquecimento (AQ), tração irregular (TI) ou ambos (AT). Registros anteriores permitiram o levantamento das seguintes probabilidades condicionais – $p(x_j|\omega_i)$:

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,1	0,4	0,5
Transmissão (ω_2)	0,5	0,3	0,2

Além disso, sabe-se que 60% das falhas são devido a problemas na transmissão. Então $p(\omega_2) = 0,6$ (e, obviamente, $p(\omega_1) = 0,4$).

Abordagem Bayesiana



Exemplo (cont.)

Primeiramente, calculam-se $p(\omega_i)p(x_j|\omega_i)$ para em seguida obter as probabilidades marginais $p(x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,04	0,16	0,20
Transmissão (ω_2)	0,30	0,18	0,12
Prob. marginal $p(x_j)$	0,34	0,34	0,32

Finalmente, calculam-se as probabilidades *a posteriori* $p(\omega_i|x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	4/34	16/34	20/32
Transmissão (ω_2)	30/34	18/34	12/32

Resumindo, antes 3:2 falhas seriam atribuídas à transmissão. Agora, 15:2 falhas seriam atribuídas à transmissão se observar x_1 , 9:8 falhas seriam atribuídas à transmissão se observar x_2 , e 5:3 falhas seriam atribuídas ao motor se observar x_3 (observe que é diferente da maioria simples).

Abordagem Bayesiana



Exemplo (cont.)

Primeiramente, calculam-se $p(\omega_i)p(x_j|\omega_i)$ para em seguida obter as probabilidades marginais $p(x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,04	0,16	0,20
Transmissão (ω_2)	0,30	0,18	0,12
Prob. marginal $p(x_j)$	0,34	0,34	0,32

Finalmente, calculam-se as probabilidades *a posteriori* $p(\omega_i|x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	4/34	16/34	20/32
Transmissão (ω_2)	30/34	18/34	12/32

Resumindo, antes 3:2 falhas seriam atribuídas à transmissão. Agora, 15:2 falhas seriam atribuídas à transmissão se observar x_1 , 9:8 falhas seriam atribuídas à transmissão se observar x_2 , e 5:3 falhas seriam atribuídas ao motor se observar x_3 (observe que é diferente da maioria simples).

Abordagem Bayesiana



Exemplo (cont.)

Primeiramente, calculam-se $p(\omega_i)p(x_j|\omega_i)$ para em seguida obter as probabilidades marginais $p(x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,04	0,16	0,20
Transmissão (ω_2)	0,30	0,18	0,12
Prob. marginal $p(x_j)$	0,34	0,34	0,32

Finalmente, calculam-se as probabilidades *a posteriori* $p(\omega_i|x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	4/34	16/34	20/32
Transmissão (ω_2)	30/34	18/34	12/32

Resumindo, antes 3:2 falhas seriam atribuídas à transmissão. Agora, 15:2 falhas seriam atribuídas à transmissão se observar x_1 , 9:8 falhas seriam atribuídas à transmissão se observar x_2 , e 5:3 falhas seriam atribuídas ao motor se observar x_3 (observe que é diferente da maioria simples).

Abordagem Bayesiana



Exemplo (cont.)

Primeiramente, calculam-se $p(\omega_i)p(x_j|\omega_i)$ para em seguida obter as probabilidades marginais $p(x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,04	0,16	0,20
Transmissão (ω_2)	0,30	0,18	0,12
Prob. marginal $p(x_j)$	0,34	0,34	0,32

Finalmente, calculam-se as probabilidades *a posteriori* $p(\omega_i|x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	4/34	16/34	20/32
Transmissão (ω_2)	30/34	18/34	12/32

Resumindo, antes 3:2 falhas seriam atribuídas à transmissão. Agora, 15:2 falhas seriam atribuídas à transmissão se observar x_1 , 9:8 falhas seriam atribuídas à transmissão se observar x_2 , e 5:3 falhas seriam atribuídas ao motor se observar x_3 (observe que é diferente da maioria simples).

Abordagem Bayesiana



Exemplo (cont.)

Primeiramente, calculam-se $p(\omega_i)p(x_j|\omega_i)$ para em seguida obter as probabilidades marginais $p(x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	0,04	0,16	0,20
Transmissão (ω_2)	0,30	0,18	0,12
Prob. marginal $p(x_j)$	0,34	0,34	0,32

Finalmente, calculam-se as probabilidades *a posteriori* $p(\omega_i|x_j)$.

Localização da Falha	AQ (x_1)	TI (x_2)	AT (x_3)
Motor (ω_1)	4/34	16/34	20/32
Transmissão (ω_2)	30/34	18/34	12/32

Resumindo, antes 3:2 falhas seriam atribuídas à transmissão. Agora, 15:2 falhas seriam atribuídas à transmissão se observar x_1 , 9:8 falhas seriam atribuídas à transmissão se observar x_2 , e 5:3 falhas seriam atribuídas ao motor se observar x_3 (observe que é diferente da maioria simples).

Abordagem Bayesiana



Um exemplo importante de função de densidade de probabilidade condicional para classes é a distribuição normal $p(\mathbf{x}|\omega_i) \sim N(\mu_i, \Sigma_i)$ em que $\mu_i \in \mathbb{R}^n$ representa a média da classe ω_i e $\Sigma_i \in \mathbb{R}^{n \times n}$ é uma matriz de covariância.

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{n/2} \sqrt{|\Sigma_i|}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) \right]$$

Na versão unidimensional, $\mathbf{x}$ e μ são escalares e Σ_i se reduz a variância de x para a classe ω_i (representado por σ_i^2), assim $p(x|\omega_i) \sim N(\mu_i, \sigma_i^2)$

$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp \left[-\frac{1}{2} \left(\frac{x - \mu_i}{\sigma_i} \right)^2 \right]$$

A distribuição normal (ou de Gauss) reflete a situação em que existe um “protótipo ideal” da classe ω_i e os demais membros da classe são versões ligeiramente distorcidas dele.

Abordagem Bayesiana



Um exemplo importante de função de densidade de probabilidade condicional para classes é a distribuição normal $p(\mathbf{x}|\omega_i) \sim N(\mu_i, \Sigma_i)$ em que $\mu_i \in \mathbb{R}^n$ representa a média da classe ω_i e $\Sigma_i \in \mathbb{R}^{n \times n}$ é uma matriz de covariância.

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{n/2} \sqrt{|\Sigma_i|}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) \right]$$

Na versão unidimensional, $\mathbf{x}$ e μ são escalares e Σ_i se reduz a variância de x para a classe ω_i (representado por σ_i^2), assim $p(\mathbf{x}|\omega_i) \sim N(\mu_i, \sigma_i^2)$

$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp \left[-\frac{1}{2} \left(\frac{x - \mu_i}{\sigma_i} \right)^2 \right]$$

A distribuição normal (ou de Gauss) reflete a situação em que existe um “protótipo ideal” da classe ω_i e os demais membros da classe são versões ligeiramente distorcidas dele.

Abordagem Bayesiana



Um exemplo importante de função de densidade de probabilidade condicional para classes é a distribuição normal $p(\mathbf{x}|\omega_i) \sim N(\mu_i, \Sigma_i)$ em que $\mu_i \in \mathbb{R}^n$ representa a média da classe ω_i e $\Sigma_i \in \mathbb{R}^{n \times n}$ é uma matriz de covariância.

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{n/2} \sqrt{|\Sigma_i|}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) \right]$$

Na versão unidimensional, $\mathbf{x}$ e μ são escalares e Σ_i se reduz a variância de x para a classe ω_i (representado por σ_i^2), assim $p(\mathbf{x}|\omega_i) \sim N(\mu_i, \sigma_i^2)$


$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp \left[-\frac{1}{2} \left(\frac{x - \mu_i}{\sigma_i} \right)^2 \right]$$

A distribuição normal (ou de Gauss) reflete a situação em que existe um “protótipo ideal” da classe ω_i e os demais membros da classe são versões ligeiramente distorcidas dele.


Abordagem Bayesiana




Exemplos de Distribuições Normais




$$\Sigma = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 8 & 0 \\ 0 & 1 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 4 & -4 \\ -4 & 6 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 4 & 4 \\ 4 & 6 \end{bmatrix}$$

Abordagem Bayesiana



As probabilidades *a posteriori* podem ser usadas como funções discriminantes:

$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x}), i = 1, \dots, c.$$

Assim, pode-se reescrever "*maximum membership rule*" como:

$$D(\mathbf{x}) = \omega_{j^*} \in \Omega \iff P(\omega_{j^*}|\mathbf{x}) = \max_{i=1,\dots,c} \{P(\omega_i|\mathbf{x})\}$$

Na verdade, pode-se obter as mesmas regiões de classificação usando as seguintes funções:

$$g_i(\mathbf{x}) = P(\omega_i) p(\mathbf{x}|\omega_i), i = 1, \dots, c.$$

Outra possibilidade usada na literatura é a seguinte:

$$g_i(\mathbf{x}) = \log(P(\omega_i) p(\mathbf{x}|\omega_i)), i = 1, \dots, c.$$

Abordagem Bayesiana



As probabilidades *a posteriori* podem ser usadas como funções discriminantes:

$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x}), i = 1, \dots, c.$$

Assim, pode-se reescrever “*maximum membership rule*” como:

$$D(\mathbf{x}) = \omega_{i^*} \in \Omega \iff P(\omega_{i^*}|\mathbf{x}) = \max_{i=1,\dots,c} \{P(\omega_i|\mathbf{x})\}$$

Na verdade, pode-se obter as mesmas regiões de classificação usando as seguintes funções:

$$g_i(\mathbf{x}) = P(\omega_i) p(\mathbf{x}|\omega_i), i = 1, \dots, c.$$

Outra possibilidade usada na literatura é a seguinte:

$$g_i(\mathbf{x}) = \log(P(\omega_i) p(\mathbf{x}|\omega_i)), i = 1, \dots, c.$$

Abordagem Bayesiana



As probabilidades *a posteriori* podem ser usadas como funções discriminantes:

$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x}), i = 1, \dots, c.$$

Assim, pode-se reescrever “*maximum membership rule*” como:

$$D(\mathbf{x}) = \omega_{i^*} \in \Omega \iff P(\omega_{i^*}|\mathbf{x}) = \max_{i=1,\dots,c} \{P(\omega_i|\mathbf{x})\}$$

Na verdade, pode-se obter as mesmas regiões de classificação usando as seguintes funções:

$$g_i(\mathbf{x}) = P(\omega_i) p(\mathbf{x}|\omega_i), i = 1, \dots, c.$$

Outra possibilidade usada na literatura é a seguinte:

$$g_i(\mathbf{x}) = \log(P(\omega_i) p(\mathbf{x}|\omega_i)), i = 1, \dots, c.$$

Abordagem Bayesiana



As probabilidades *a posteriori* podem ser usadas como funções discriminantes:

$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x}), i = 1, \dots, c.$$

Assim, pode-se reescrever “*maximum membership rule*” como:

$$D(\mathbf{x}) = \omega_{i^*} \in \Omega \iff P(\omega_{i^*}|\mathbf{x}) = \max_{i=1,\dots,c} \{P(\omega_i|\mathbf{x})\}$$

Na verdade, pode-se obter as mesmas regiões de classificação usando as seguintes funções:

$$g_i(\mathbf{x}) = P(\omega_i) p(\mathbf{x}|\omega_i), i = 1, \dots, c.$$

Outra possibilidade usada na literatura é a seguinte:

$$g_i(\mathbf{x}) = \log(P(\omega_i) p(\mathbf{x}|\omega_i)), i = 1, \dots, c.$$

Abordagem Bayesiana



Exemplos de Funções Discriminantes

$$P(\omega_1) = 0,45$$


$$p(x|\omega_1) \sim N(4, (2, 0)^2)$$

$$P(\omega_2) = 0,35$$

$$p(x|\omega_2) \sim N(5, (1, 2)^2)$$

$$P(\omega_3) = 0,20$$

$$p(x|\omega_3) \sim N(7, (1, 0)^2)$$



Abordagem Bayesiana



Seja D^* um classificador que atribui sempre o rótulo da classe de maior probabilidade *a posteriori*. Como para cada $\mathbf{x}$, a probabilidade de se estar correto é

$$P(\omega_{i^*}|\mathbf{x}) = \max_{i=1,\dots,c} \{P(\omega_i|\mathbf{x})\}$$

Temos que a probabilidade de erro de D^* é dada pela soma de erros para cada $\mathbf{x}$ ponderados pela probabilidade $p(\mathbf{x})$ de sua ocorrência:

$$P_e(D^*) = \int_{\mathbb{R}^n} (1 - P(\omega_{i^*}|\mathbf{x})) p(\mathbf{x}) d\mathbf{x}.$$

Separando em c integrais, temos em que $\mathcal{R}_i^*$ é a região de classificação da classe ω_i :

$$P_e(D^*) = \sum_{i=1}^c \int_{\mathcal{R}_i^*} (1 - P(\omega_i|\mathbf{x})) p(\mathbf{x}) d\mathbf{x}.$$

O erro de D^* é o menor erro possível e é chamado de erro de Bayes (ou taxa de erro de Bayes).

Abordagem Bayesiana



Seja D^* um classificador que atribui sempre o rótulo da classe de maior probabilidade *a posteriori*. Como para cada $\mathbf{x}$, a probabilidade de se estar correto é

$$P(\omega_{i^*}|\mathbf{x}) = \max_{i=1,\dots,c} \{P(\omega_i|\mathbf{x})\}$$

Temos que a probabilidade de erro de D^* é dada pela soma de erros para cada $\mathbf{x}$ ponderados pela probabilidade $p(\mathbf{x})$ de sua ocorrência:

$$P_e(D^*) = \int_{\mathbb{R}^n} (1 - P(\omega_{i^*}|\mathbf{x})) p(\mathbf{x}) d\mathbf{x}.$$

Separando em c integrais, temos em que $\mathcal{R}_i^*$ é a região de classificação da classe ω_i :

$$P_e(D^*) = \sum_{i=1}^c \int_{\mathcal{R}_i^*} (1 - P(\omega_i|\mathbf{x})) p(\mathbf{x}) d\mathbf{x}.$$

O erro de D^* é o menor erro possível e é chamado de erro de Bayes (ou taxa de erro de Bayes).

Abordagem Bayesiana



Seja D^* um classificador que atribui sempre o rótulo da classe de maior probabilidade *a posteriori*. Como para cada $\mathbf{x}$, a probabilidade de se estar correto é

$$P(\omega_{i^*}|\mathbf{x}) = \max_{i=1,\dots,c} \{P(\omega_i|\mathbf{x})\}$$

Temos que a probabilidade de erro de D^* é dada pela soma de erros para cada $\mathbf{x}$ ponderados pela probabilidade $p(\mathbf{x})$ de sua ocorrência:

$$P_e(D^*) = \int_{\mathbb{R}^n} (1 - P(\omega_{i^*}|\mathbf{x})) p(\mathbf{x}) d\mathbf{x}.$$

Separando em c integrais, temos em que $\mathcal{R}_i^*$ é a região de classificação da classe ω_i :

$$P_e(D^*) = \sum_{i=1}^c \int_{\mathcal{R}_i^*} (1 - P(\omega_i|\mathbf{x})) p(\mathbf{x}) d\mathbf{x}.$$

O erro de D^* é o menor erro possível e é chamado de erro de Bayes (ou taxa de erro de Bayes).

Abordagem Bayesiana



Seja D^* um classificador que atribui sempre o rótulo da classe de maior probabilidade *a posteriori*. Como para cada $\mathbf{x}$, a probabilidade de se estar correto é

$$P(\omega_{i^*}|\mathbf{x}) = \max_{i=1,\dots,c} \{P(\omega_i|\mathbf{x})\}$$

Temos que a probabilidade de erro de D^* é dada pela soma de erros para cada $\mathbf{x}$ ponderados pela probabilidade $p(\mathbf{x})$ de sua ocorrência:

$$P_e(D^*) = \int_{\mathbb{R}^n} (1 - P(\omega_{i^*}|\mathbf{x})) p(\mathbf{x}) d\mathbf{x}.$$

Separando em c integrais, temos em que $\mathcal{R}_i^*$ é a região de classificação da classe ω_i :

$$P_e(D^*) = \sum_{i=1}^c \int_{\mathcal{R}_i^*} (1 - P(\omega_i|\mathbf{x})) p(\mathbf{x}) d\mathbf{x}.$$

O erro de D^* é o menor erro possível e é chamado de erro de Bayes (ou taxa de erro de Bayes).

Abordagem Bayesiana



Se usarmos a definição de probabilidade *a posteriori* no erro de D^* , temos

$$\begin{aligned}
 P_e(D^*) &= \sum_{i=1}^c \int_{\mathcal{R}_i^*} \left(1 - \frac{P(\omega_i)p(\mathbf{x}|\omega_i)}{p(\mathbf{x})} \right) p(\mathbf{x}) d\mathbf{x} \\
 &= \int_{\mathbb{R}^n} p(\mathbf{x}) d\mathbf{x} - \sum_{i=1}^c \int_{\mathcal{R}_i^*} P(\omega_i)p(\mathbf{x}|\omega_i) d\mathbf{x} \\
 &= 1 - \sum_{i=1}^c \int_{\mathcal{R}_i^*} P(\omega_i)p(\mathbf{x}|\omega_i) d\mathbf{x} \\
 &= 1 - P_c(D^*)
 \end{aligned}$$

O valor $P_c(D^*)$ representa a probabilidade de acerto de D^* .

Abordagem Bayesiana



Se usarmos a definição de probabilidade *a posteriori* no erro de D^* , temos

$$\begin{aligned} P_e(D^*) &= \sum_{i=1}^c \int_{\mathcal{R}_i^*} \left(1 - \frac{P(\omega_i)p(\mathbf{x}|\omega_i)}{p(\mathbf{x})} \right) p(\mathbf{x}) d\mathbf{x} \\ &= \int_{\mathbb{R}^n} p(\mathbf{x}) d\mathbf{x} - \sum_{i=1}^c \int_{\mathcal{R}_i^*} P(\omega_i)p(\mathbf{x}|\omega_i) d\mathbf{x} \\ &= 1 - \sum_{i=1}^c \int_{\mathcal{R}_i^*} P(\omega_i)p(\mathbf{x}|\omega_i) d\mathbf{x} \\ &= 1 - P_c(D^*) \end{aligned}$$

O valor $P_c(D^*)$ representa a probabilidade de acerto de D^* .

Abordagem Bayesiana



Exemplo de Erro de Bayes

$$x \in \mathbb{R}$$

$$\Omega = \{\omega_1, \omega_2\}$$

$$g_i(x) = P(\omega_i)p(x|\omega_i), i = 1, 2, x \in [0, 10]$$

